Curso Análisis de Datos y Machine Learning con Python

Programa modular · Python · Análisis de datos · Machine Learning

FUNDAMENTOS APLICADOS | 2 HORAS PRESENCIALES A LA SEMANA | 3 MÓDULOS | 48 HORAS

Los datos se han convertido en el nuevo insumo estratégico y la inteligencia artificial en la maquinaria que los transforma en diagnósticos, hallazgos y conocimiento para la toma de decisiones. Para quienes analizan comercio exterior, exportaciones, inversión extranjera y turismo, ya no basta con leer cifras agregadas: se necesitan herramientas para explorar grandes volúmenes de información, encontrar patrones, predecir comportamientos y sustentar decisiones con evidencia.

Este curso está diseñado para quienes quieran dominar tres competencias muy demandadas hoy: programación en Python, análisis y visualización de datos y técnicas de inteligencia artificial aplicadas a casos de negocio como predicción de demanda, determinación de precios, segmentación de mercados, creación de índices económicos, campañas de marketing, fuga de clientes, entre otros.

El programa está dividido en tres módulos independientes y consecutivos. Cada participante puede inscribirse únicamente en los módulos de su interés, siguiendo el orden sugerido de dificultad y recibe un certificado de asistencia por cada módulo que complete.

De forma práctica, aprenderá a:

- ✓ Programar en Python desde cero.
- ✓ Conectarse y extraer datos económicos de fuentes reales.
- ✓ Analizar, transformar y visualizar datos con NumPy, Pandas, Matplotlib y Seaborn, entre otras librerías.
- ✓ Aplicar algoritmos de machine learning supervisado y no supervisado para detectar patrones, clasificar y predecir variables socioeconómicas.
- ✓ Evaluar el desempeño de los modelos.

DURACIÓN TOTAL: 48 HORAS DE CLASE

Módulo	Sesiones	Horas clase	Trabajo autónomo
Módulo 1 — Programación en Python	6	12 horas	12 horas
Módulo 2 — Análisis y visualización de datos	8	16 horas	16 horas
Módulo 3 — Machine learning	10	20 horas	20 horas
Total	**24**	**48 horas**	**48 horas**

Cada sesión dura 2 horas y hay una sesión por semana, de modo que el programa completo se dicta en 24 semanas. La dedicación total estimada es de 96 horas (48 de clase y 48 de trabajo autónomo).

PERFIL DE INGRESO Y DE EGRESO

Mínimo de ingreso:

- No se requiere experiencia previa en programación.
- Manejo básico de Windows y Excel.
- Nociones de estadística descriptiva (promedios, dispersión, correlación).
- Habilidades básicas de comprensión de lectura, matemáticas y razonamiento abstracto.
- Computador con conexión a internet.

Mínimo de egreso:

- Escribir y depurar código Python usando su sintaxis básica, estructuras de datos, bucles y manejo de errores.
- Cargar, integrar, limpiar y transformar bases de datos de distintas fuentes y formatos.
- Realizar un análisis exploratorio y comunicar hallazgos con visualizaciones claras.
- Construir, ajustar y evaluar modelos de regresión, clasificación y agrupamiento.
- Reconocer cuándo un problema del negocio se puede resolver con machine learning y cuándo no.

OBJETIVOS Y PRERREQUISITOS

Objetivos

Aprenderá a programar en Python desde cero: sintaxis, tipos de objetos, estructuras de datos, condicionales, bucles, funciones y manejo de errores, además del uso de Google Colab, VS Code, ambientes virtuales y control de versiones con Git y GitHub.

Desarrollará habilidades para recolectar, importar, combinar y exportar datos y para preparar conjuntos de información mediante limpieza, imputación, estandarización y feature engineering, incluido el tratamiento de datos geográficos y análisis de texto.

Aplicará técnicas de machine learning supervisado y no supervisado —agrupamiento, reglas de asociación, reducción de dimensionalidad, regresión y clasificación— y aprenderá a validar y optimizar modelos evitando el sobreajuste.

Prerrequisitos

- Capacidad para analizar situaciones y encontrar soluciones de manera estructurada.
- Familiaridad con herramientas digitales, navegación en internet y gestión de archivos.
- Disponibilidad para asistir a una sesión presencial de 2 horas una vez a la semana.
- Curiosidad, disciplina, trabajo autónomo y ganas de enfrentar desafíos prácticos con datos.

Orden recomendado

Los módulos 2 y 3 asumen el manejo de Python del módulo 1. Quien ya programe en Python puede inscribirse directamente al módulo 2 y quien ya programe y realice análisis y visualización de datos en Python puede inscribirse directamente al módulo 3.

QUÉ INCLUYE EL CURSO Y QUÉ NO

El enfoque es de amplitud sobre profundidad: dotar al participante de un portafolio versátil de herramientas y algoritmos, no agotar la teoría de cada uno. Este es el alcance:

Sí se enseña

- ✓ Programación en Python desde cero con Google Colab y GitHub. Instrucciones adicionales para utilizar VS Code, ambientes virtuales y Git en computador personal.
- ✓ Importación, combinación, limpieza, transformación y exportación de datos con Pandas y NumPy.
- ✓ Análisis exploratorio y visualización con Matplotlib y Seaborn; procesamiento de datos geográficos y análisis de texto.
- ✓ Preprocesamiento y feature engineering: imputación, estandarización, creación y selección de variables.
- ✓ Machine learning no supervisado: agrupamiento, reglas de asociación y reducción de dimensionalidad.
- ✓ Machine learning supervisado: regresión lineal, polinómica, Ridge y Lasso, regresión logística, KNN, árboles de decisión, Random Forest, Gradient Boosting y XGBoost.
- ✓ Validación y optimización: partición entrenamiento/prueba, métricas de desempeño, matriz de confusión, curva ROC, overfitting, validación cruzada, hiperparámetros y clases desbalanceadas.

No se enseña

- ✗ No es un curso de teoría estadística o econométrica formal: no se hacen demostraciones matemáticas de los algoritmos. Profundizar en la teoría queda a cargo de cada participante.
- ✗ No cubre deep learning, redes neuronales, procesamiento de lenguaje natural ni IA generativa.
- ✗ No cubre desarrollo web ni construcción de aplicaciones web (HTML, CSS, JavaScript, React, Streamlit, Django, Flask o FastAPI).
- ✗ No cubre Tableau, Power BI, Excel avanzado, R ni Stata: la herramienta del curso es Python.
- ✗ No cubre SQL, ingeniería de datos, puesta en producción (MLOps) ni ecosistema en la nube (Snowflake).

METODOLOGÍA Y SEGUIMIENTO

La metodología es eminentemente práctica (hands-on / aprender haciendo). El tiempo de clase se dedica a resolver casos de negocio con datos reales o simulados, estructurados específicamente para facilitar el aprendizaje y enfrentar los desafíos del mundo laboral.

Cómo se desarrolla cada sesión

- Quiz/Kahoot de apertura sobre los temas de la sesión anterior. Se comparten las respuestas correctas para que cada participante compare y mida su propio avance.
- Explicación del tema del día por parte de la docente, con código en vivo. Los notebooks tienen vacíos que deben ser completados por los estudiantes.
- Taller en clase para aplicar el tema y resolver dudas en el momento. Al cierre se entrega la solución del taller para que el estudiante pueda comparar sus respuestas, identificar errores y corregir.
- Todo el material queda disponible en el repositorio del curso en GitHub.

Seguimiento y certificación

El curso no tiene evaluaciones calificadas: los quices y talleres son instrumentos de autoevaluación y el único registro que se lleva es la asistencia, complementada por el trabajo autónomo de cada participante.

Se emite un certificado de asistencia por cada módulo cursado. Para obtenerlo se requiere asistir como mínimo al 80% de las sesiones del módulo y haber realizado por lo menos el 80% de los quices y de los talleres.

CONTENIDO DEL PROGRAMA

24 sesiones distribuidas en tres módulos independientes. La inscripción se hace por módulo.

1 Módulo 1 — Programación en Python

6 sesiones · 12 horas de clase · sin requisitos previos

Cierra la brecha de entrada: al terminar, el participante escribe y depura su propio código en Python y trabaja de forma ordenada y versionada.

Presentación del curso: Alcance del programa y forma de trabajo.

Conceptos fundamentales de IA. Introducción a la inteligencia artificial y al machine learning: qué es cada cosa, en qué se diferencian el aprendizaje supervisado y el no supervisado y qué tipo de preguntas del negocio se pueden responder con estas técnicas.

Entorno de trabajo: Introducción a Python, Jupyter Notebook, Google Colab, VS Code, ambientes virtuales, Git y GitHub.

Gestión de información y tipos de objetos. Cómo Python guarda y clasifica la información: variables, tipos de objetos y estructuras de datos. Se trabaja con listas y listas de listas, la estructura base para representar tablas y registros. Tuplas como estructuras inmutables. Manipulación de cadenas de texto (strings), clave para limpiar nombres de países, productos, partidas o empresas. Uso de conjuntos para identificar valores únicos, comparar listados y detectar diferencias entre bases de datos. Diccionarios como estructura clave-valor.

Lógica de programación, condicionales, bucles y creación de funciones. Función range y operadores aritméticos, lógicos y relacionales de Python. Uso de if, elif, else, for y while para automatizar tareas repetitivas y creación de funciones propias para reutilizar código y organizar el trabajo de forma modular. Manejo de excepciones y errores dentro de funciones para escribir código robusto.

El módulo cierra con un reto práctico en equipos que integra todo el módulo: leer información, procesarla con funciones, condicionales y bucles y producir un resultado.

2 Módulo 2 — Análisis y visualización de datos

8 sesiones · 16 horas de clase · requiere Python básico

El módulo más cercano al trabajo diario de un equipo de análisis de datos: convertir archivos dispersos y sucios en una base confiable y en hallazgos comunicables.

Importación y extracción de datos. Métodos de recolección e importación desde las fuentes más comunes —Excel, CSV, archivos de texto, web y fuentes de datos económicos— hacia un DataFrame de Pandas listo para trabajar.

Combinación y exportación de datos. Integración de múltiples conjuntos de datos mediante merge y concatenación, manejo de llaves que no coinciden, y exportación de resultados en los formatos requeridos para informes y tableros.

Preparación y limpieza de datos. Identificación y tratamiento de valores nulos, duplicados, categorías mal escritas y tipos de datos incorrectos. Estrategias de imputación y criterios para decidir cuándo eliminar y cuándo reemplazar.

Manipulación y transformación de datos. Filtros, ordenamientos, agrupaciones (groupby), creación de nuevas variables y reestructuración de tablas (reshape) para pasar de datos crudos a la vista que necesita el análisis.

Análisis exploratorio de datos. Estadísticas descriptivas, distribuciones, valores atípicos y relaciones entre variables, con visualizaciones en Matplotlib y Seaborn: histogramas, boxplots, dispersión y mapas de calor.

Preprocesamiento, feature engineering y estandarización. Construcción de variables nuevas con contenido económico, codificación de variables categóricas y estandarización de escalas, pasos indispensables antes de aplicar cualquier modelo.

Procesamiento de datos geográficos. Manejo de información con componente territorial —países, regiones, departamentos y municipios— y su representación en mapas para analizar mercados, destinos y orígenes de manera visual.

Minería de texto y análisis de sentimientos. Procesamiento de datos no estructurados para extraer valor de documentos o comentarios. Incluye técnicas de limpieza de texto, visualización mediante nubes de palabras y evaluación de opiniones.

Reto integrador de preparación de datos. Ejercicio práctico en equipos sobre una base desordenada: limpiarla, integrarla, construir variables y dejarla lista para análisis, aplicando todo lo visto en el módulo.

3 Módulo 3 — Machine learning

10 sesiones · 20 horas de clase · requiere los módulos 1 y 2 o equivalente

El portafolio de algoritmos: agrupar, reducir, predecir y clasificar, con el criterio necesario para evaluar si un modelo sirve o no.

Aprendizaje no supervisado

Métodos de agrupamiento. Técnicas de clustering para descubrir grupos que no están etiquetados en los datos: segmentación de empresas, mercados, productos o perfiles de visitantes, y cómo interpretar y nombrar los grupos obtenidos.

Aprendizaje por reglas de asociación. Detección de patrones de co-ocurrencia del tipo "cuando ocurre A, tiende a ocurrir B": canastas de productos, combinaciones de destinos y de servicios, con métricas de soporte, confianza y lift.

Técnicas de reducción de dimensionalidad. Cómo resumir muchas variables en pocos componentes que conservan la información relevante, para visualizar bases complejas y mejorar el desempeño de los modelos.

Aprendizaje supervisado

Regresión lineal y evaluación de modelos. Primer modelo supervisado de principio a fin: división del conjunto de datos en entrenamiento y prueba, ajuste del modelo, interpretación de coeficientes y medidas de evaluación del error.

Regresión polinómica, regularización y selección de variables. Relaciones no lineales, diagnóstico de overfitting y underfitting, regularización con Ridge y Lasso, y criterios para seleccionar las variables que realmente aportan.

Regresión logística y métricas de clasificación. Predicción de resultados binarios —por ejemplo, si una empresa exportará o no, o si un cliente se retirará— e interpretación de la matriz de confusión, precisión, recall y curva ROC.

KNN, árboles de decisión y optimización. Dos algoritmos muy interpretables, validación cruzada y selección de hiperparámetros para elegir la configuración que generaliza mejor.

Métodos de ensamble. Random Forest, Gradient Boosting y XGBoost: por qué combinar muchos modelos débiles funciona mejor, cómo leer la importancia de las variables y cómo manejar clases desbalanceadas.

Reto integrador de selección del mejor modelo. Ejercicio en equipos sobre un mismo problema y una misma base: entrenar varios modelos, compararlos con criterios de desempeño y sustentar la elección del mejor.

CALENDARIO PROPUESTO

Propuesta de programación con una sesión semanal de 2 horas, los martes a las 10 a.m. El programa completo se dicta en 24 semanas.

Módulo	Sesiones	Inicio	Cierre	Horas
Módulo 1 — Programación en Python	6	Martes 20-Oct-2026	Martes 24-Nov-2026	12
Módulo 2 — Análisis y visualización de datos	8	Martes 26-Ene-2027	Martes 16-Mar-2027	16
Módulo 3 — Machine learning	10	Martes 6-Abr-2027	Martes 8-Jun-2027	20
Programa completo	**24**	**20-Oct-2026**	**8-Jun-2027**	**48**

Inscripción por módulo

Quien se inscriba a un solo módulo asiste únicamente a las fechas de ese módulo.

HERRAMIENTAS, MATERIAL Y BIBLIOGRAFÍA

Herramientas que se usarán

Python, Jupyter Notebook, Google Colab, GitHub. Librerías: NumPy, Pandas, Matplotlib, Seaborn, Scikit-learn y XGBoost, entre otras. Todas son gratuitas y de código abierto.

Material del curso

- Notebooks de clase con el código explicado paso a paso.
- Bases de datos para cada sesión.
- Talleres y sus soluciones y quices con las respuestas correctas.
- Repositorio en GitHub con todo el material, disponible durante el curso.

Bibliografía de referencia

- Severance, C. (2020). Python para Todos: Explorando la información con Python. Independently Published.
- McKinney, W. (2022). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter. Tercera edición. O'Reilly Media.
- Géron, A. (2017). Hands-On Machine Learning with Scikit-Learn & TensorFlow. O'Reilly Media.
- Hastie, T., Tibshirani, R., & Friedman, J. (2017). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer.
- Kotu, V., & Deshpande, B. (2018). Data Science: Concept and Practice. Segunda edición. Morgan Kaufmann.

INSCRIPCIONES

La inscripción se realiza por módulo. Indique en qué módulos desea participar y confirme su disponibilidad en el horario propuesto.

Docente	Lina María Castro Córdoba
Correo de contacto	lmcastro@procolombia.co
Modalidad	Presencial
Certificación	Certificado de asistencia por módulo, con mínimo 80% de asistencia a las sesiones de clase, presentación de quices y realización de talleres.
Cupo	30 cupos por orden de inscripción
Fecha límite de inscripción	Viernes, 9 de octubre de 2026
Link de inscripción	https://forms.cloud.microsoft/r/m9f25BDQcU