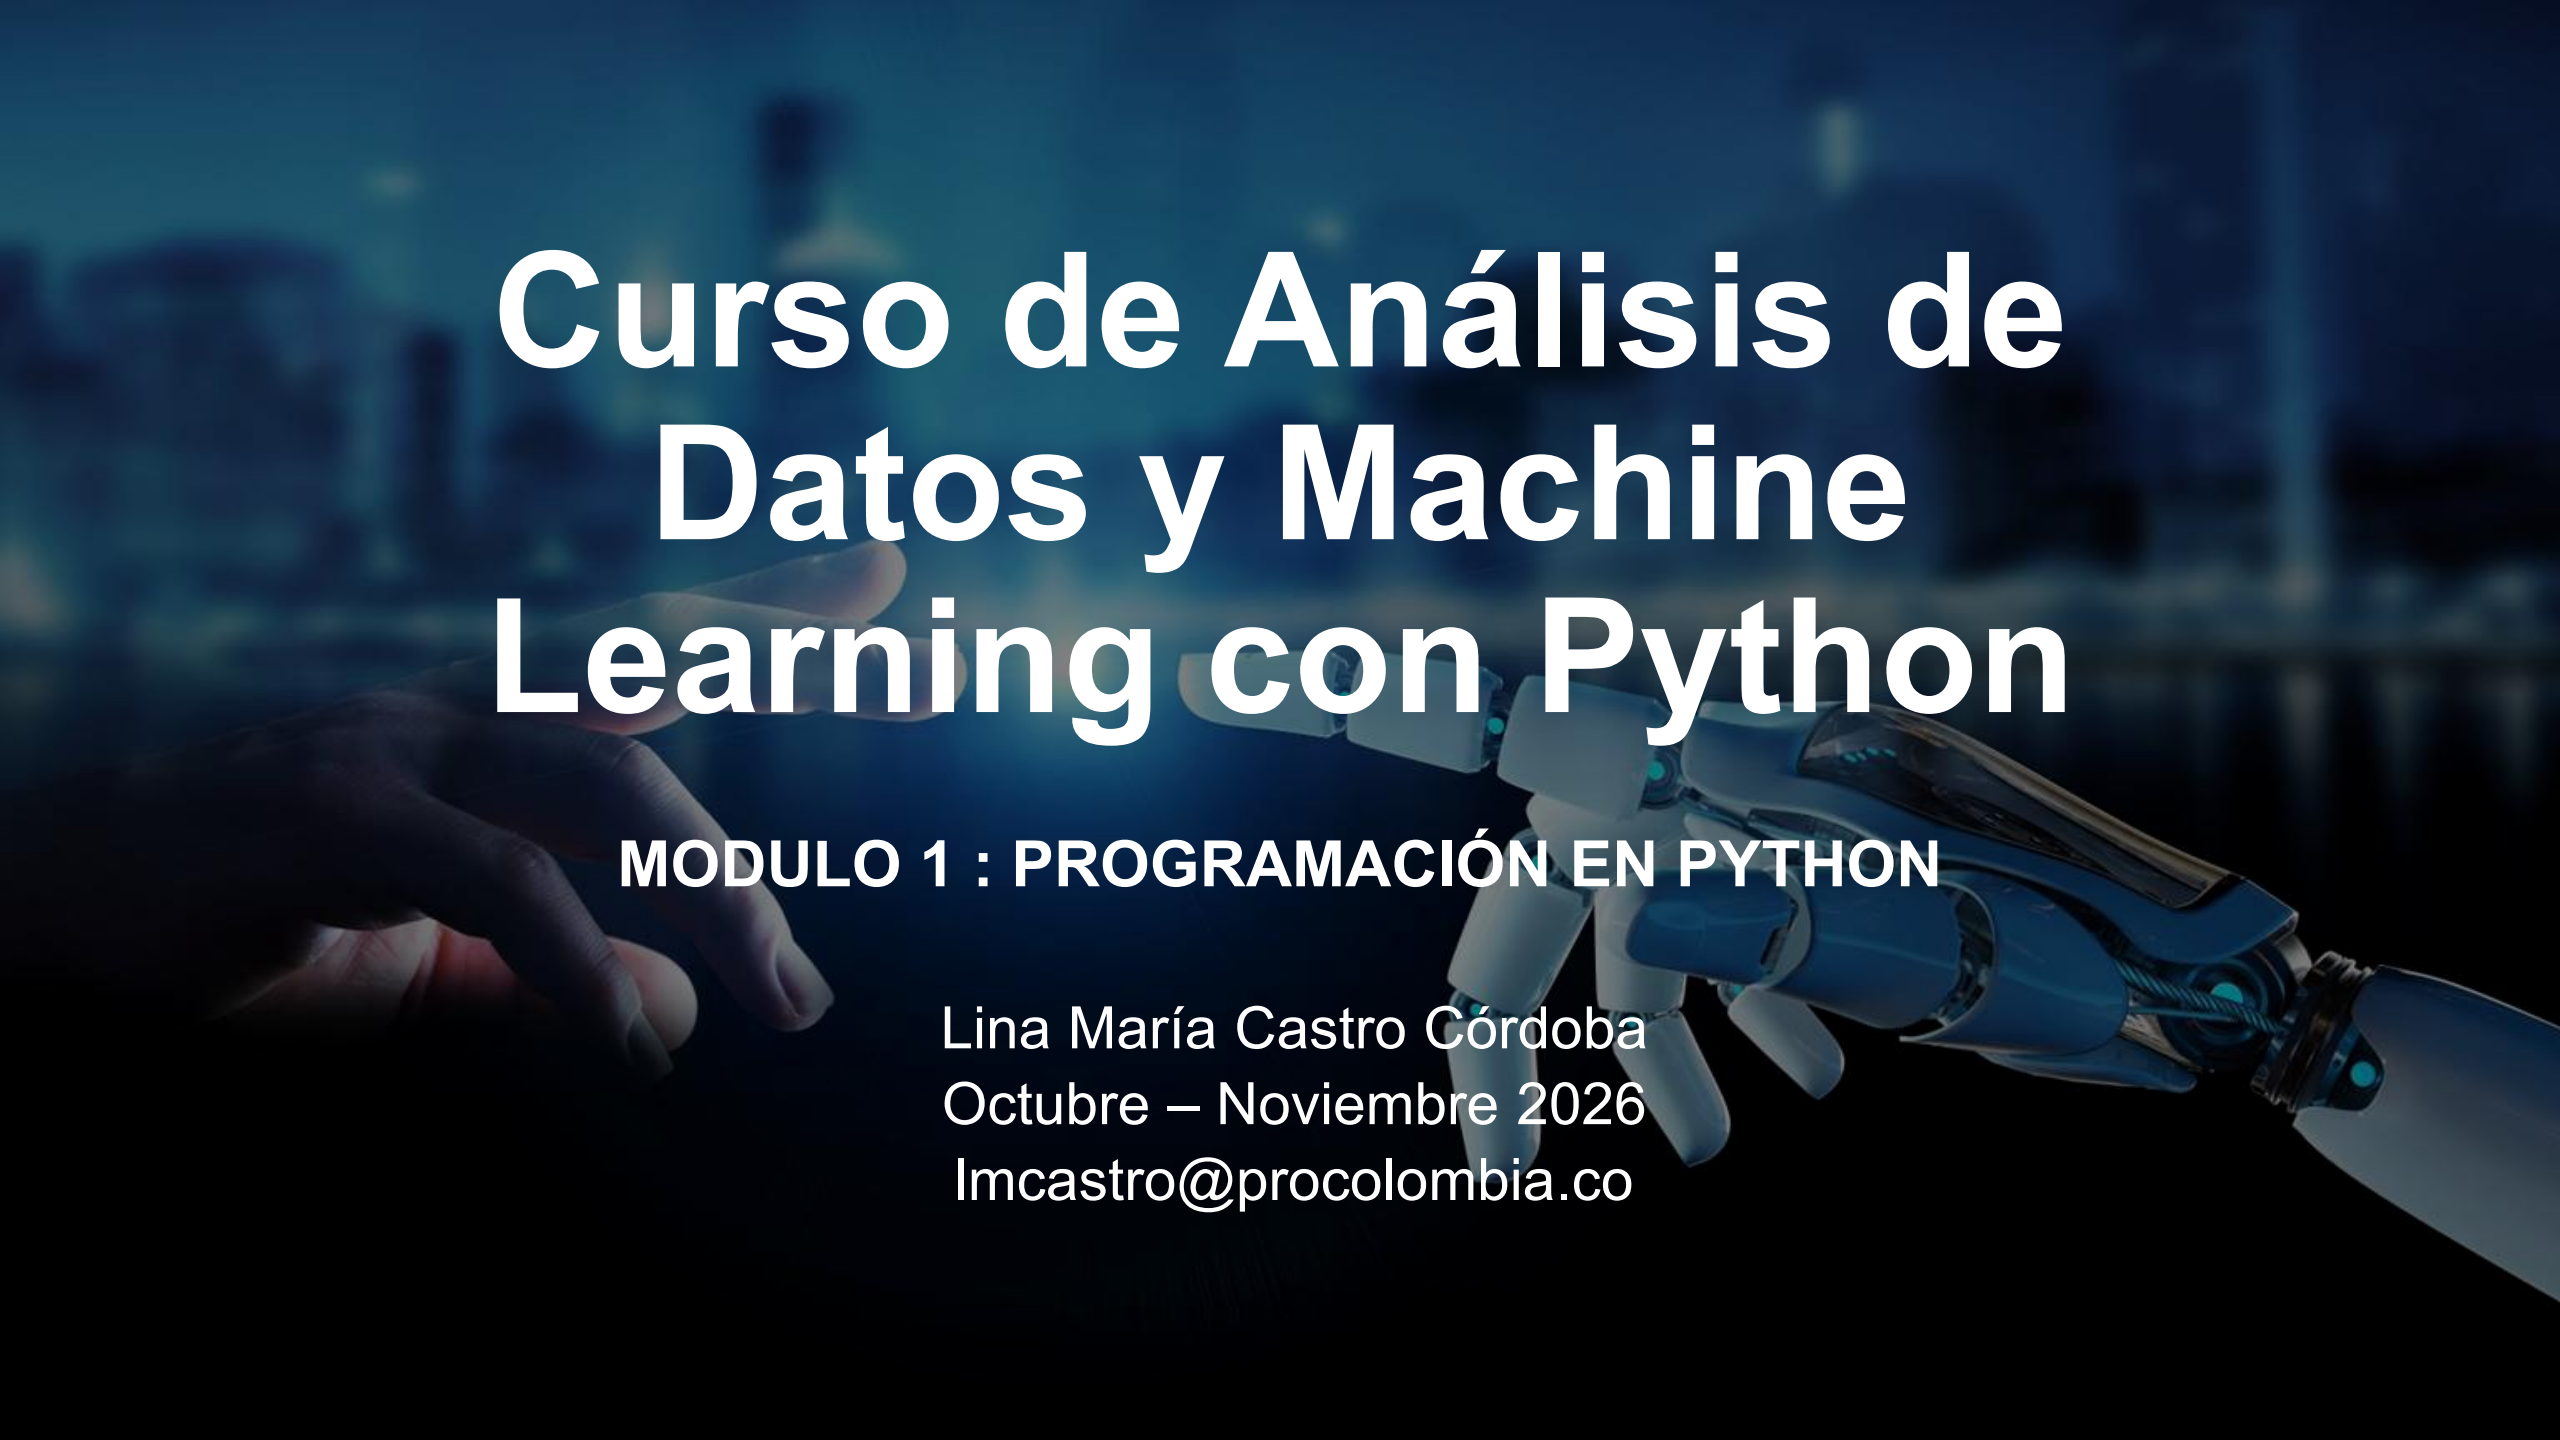


Curso de Análisis de Datos y Machine Learning con Python

MODULO 1 : PROGRAMACIÓN EN PYTHON

Lina María Castro Córdoba
Octubre – Noviembre 2026
lmcastro@procolombia.co

¿QUIÉN SOY?



1 ESTUDIOS

- **Maestría en Ciencia de Datos** – Pontificia Universidad Católica de Chile
- **Diplomado en Machine Learning and Data Science** – Universidad Nacional de Colombia
- **Maestría en Ciencias Económicas** – Universidad Nacional de Colombia
- **Economía** – Universidad Nacional de Colombia

2 EXPERIENCIA PROFESIONAL

Asesor Senior Analítica – Gerencia Inteligencia Comercial – ProColombia – 9 años

PROCOLOMBIA
EXPORTACIONES TURISMO INVERSIÓN MARCA PAÍS

DANE
INFORMACIÓN PARA TODOS

Universidad de La Sabana

Confecoop

BSD

CORHUILA

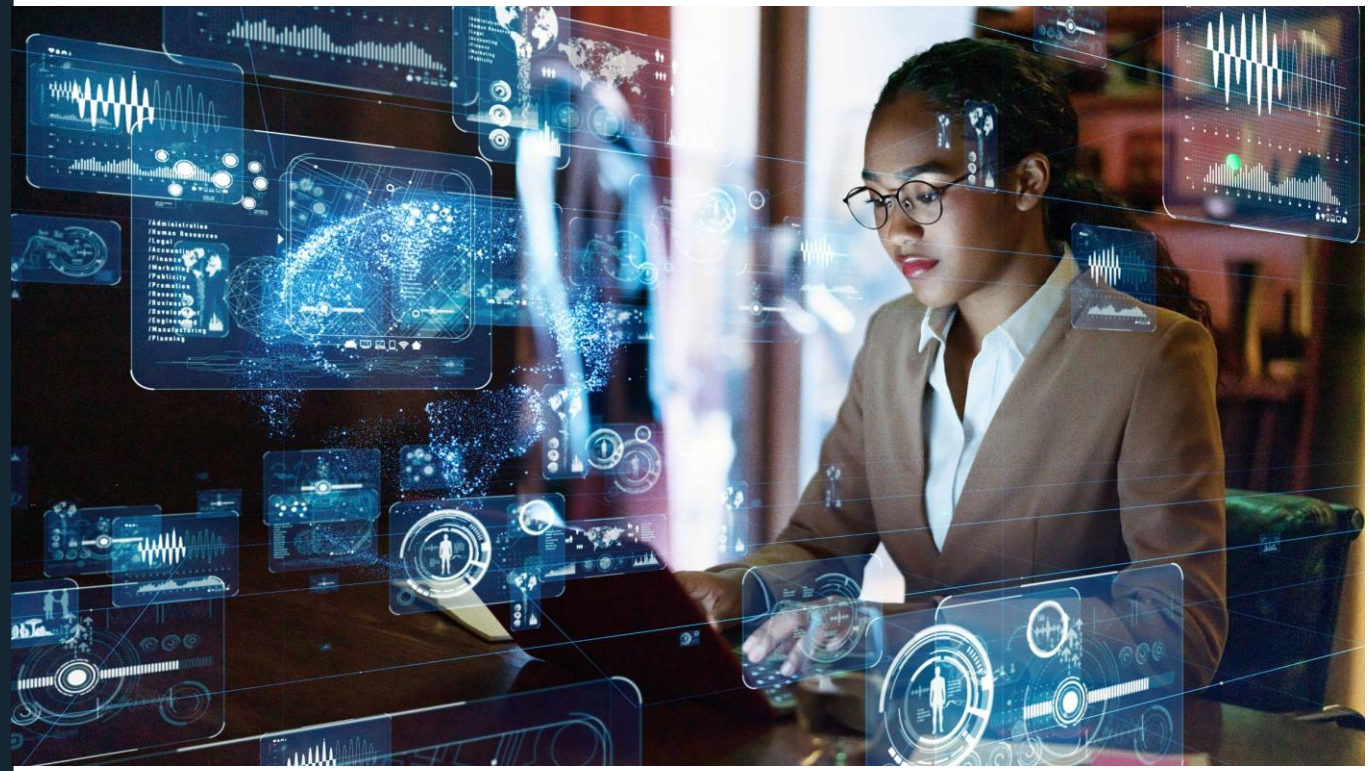
CID Centro de Investigaciones para el Desarrollo

Ministerio de Comercio, Industria y Turismo

PROFESSIONAL CERTIFICATE
CertiProf
SCRUM MASTER
SMPC

stata

snowflake



PROGRAMA DEL CURSO



CÓMO USAR LA IA GENERATIVA EN ESTE CURSO

Para los fundamentos, el aprendizaje debe ser estrictamente manual

Es vital que ustedes:

- Desarrollen el razonamiento algorítmico.
- Entiendan las estructuras de datos.
- Dominen la lectura y corrección de errores.

Si tercerizan esta base a la IA prematuramente, carecerán de la intuición lógica necesaria para dirigir, desarrollar y corregir código avanzado más adelante.

Dónde ocurre realmente el aprendizaje

Si le pides la solución a la IA

- El código funciona y el taller queda listo.
- No queda nada en ti: no viste el error, no elegiste el camino, no analizaste, no decidiste.
- La próxima vez vuelves a depender.

Si peleas con el problema 15 minutos

- Entiendes qué te estaba diciendo el error.
- Reconoces el patrón la siguiente vez que aparezca.
- La próxima vez lo resuelves sin ayuda.
- **Realmente aprendes**.

La dificultad no es un obstáculo para el aprendizaje, es el mecanismo para aprender.
Programar se aprende equivocándose y corrigiendo.

Por qué vale la pena aprender programación a pesar de la IA

Criterio

La IA escribe código que corre. No sabe si el resultado tiene sentido económico ni si los datos daban para esa conclusión. Eso lo pones tú.

Responsabilidad

El informe lo firmas tú y lo sustentas tú. Cuando alguien pregunte por qué el modelo dice eso, la IA no va a estar en la reunión.

Saber qué pedir

Sin fundamentos no sabes qué pedirle a la herramienta, ni distinguir una respuesta correcta de una que solo suena convincente.

Autonomía

Quien entiende el dato y el problema decide qué hacer. Quien solo copia queda atado a lo que la herramienta decida darle ese día.

La IA se equivoca y lo hace con mucha seguridad

Inventa

Funciones y parámetros que no existen, escritos con total naturalidad.

Filtra información

Mezcla entrenamiento y prueba y te entrega un 98% de exactitud que no significa nada.

Elige mal la métrica

Exactitud alta en una base desbalanceada donde el modelo no detecta ni un caso.

Limpia de más

Borra los atípicos que eran justamente el hallazgo que buscabas.

Ninguno de estos errores se ve desde afuera. Solo los detecta quien sabe hacerlo por su cuenta.

Casi nunca vas a acertar al primer intento. Hay que refinar la respuesta varias veces hasta llegar a lo que sirve. Pero solo puede refinar quien entiende lo que le devolvieron: el que no sabe se queda con lo primero que le dieron.

¿De verdad se va a necesitar esto en unos años?

Lo que la IA está automatizando	Lo que se vuelve más valioso
Recordar la sintaxis de una función	Saber qué transformación necesita el dato
Escribir el código de un modelo	Elegir el modelo y la métrica que responden la pregunta
Producir un gráfico o un cruce de datos	Decidir qué mostrar y qué conclusión es la adecuada
Ejecutar el análisis	Darse cuenta de que el resultado no puede ser cierto

La respuesta honesta:
Escribir código de memoria, cada vez menos. **Entender datos, modelos y sus límites, cada vez más. Sin embargo, necesitas los fundamentos para llegar a este punto.**

Las 6 reglas del curso

1. **Desactiva el autocompletado de IA en Colab antes de cada clase.**
   Si la sugerencia aparece sola, nunca vas a saber si lo sabías o no.

2. **Intenta por tu cuenta al menos 10 minutos antes de pedir ayuda.**
   Quedarse atascado un rato es parte del trabajo, no una señal de que no sirves.

3. **Antes de preguntar a la IA: mensaje de error, notebook de clase, un compañero, la docente.**
   El taller se hace en clase justamente para preguntar en el momento.

4. **Si usas IA, pídele que te explique, no que te resuelva.**
   Tutor, no sustituto: que te lleve a la solución, no que te la entregue.

5. **Nunca dejes en tu notebook código que no puedas explicar línea por línea.**
   Esa es la prueba: si no lo puedes reconstruir solo, todavía no lo aprendiste.

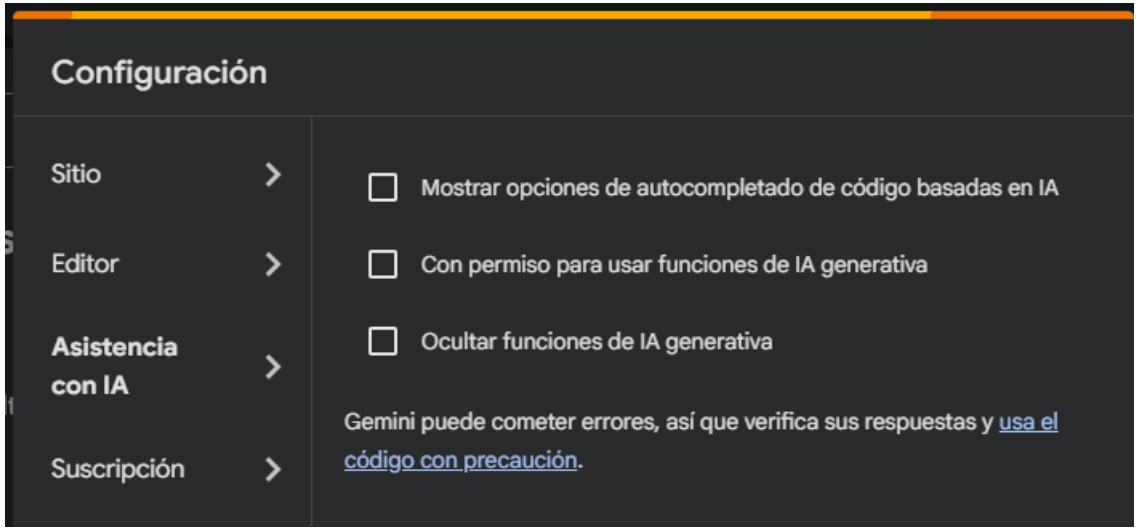
6. **Sé honesto contigo mismo en cada quiz y taller.**
   Lo importante no es la calificación hoy, lo importante es aprender para el futuro desempeño profesional.

Apagar el autocompletado en Google Colab

1. Abre cualquier notebook en Google Colab.
2. Entra al menú **Herramientas** → **Configuración** (Tools → Settings).
3. Busca la sección de **asistencia de IA** (AI Assistance).
4. Desactiva las sugerencias automáticas de código y el autocompletado generado por IA.
5. Guarda y comprueba: al escribir no debe aparecer código gris sugerido.

Por qué esta regla es la primera

El autocompletado no espera a que le preguntes: aparece antes de que termines de pensar. Es la única forma de ayuda que te quita la decisión sin que te des cuenta.



Cómo pedirle a la IA que te enseñe

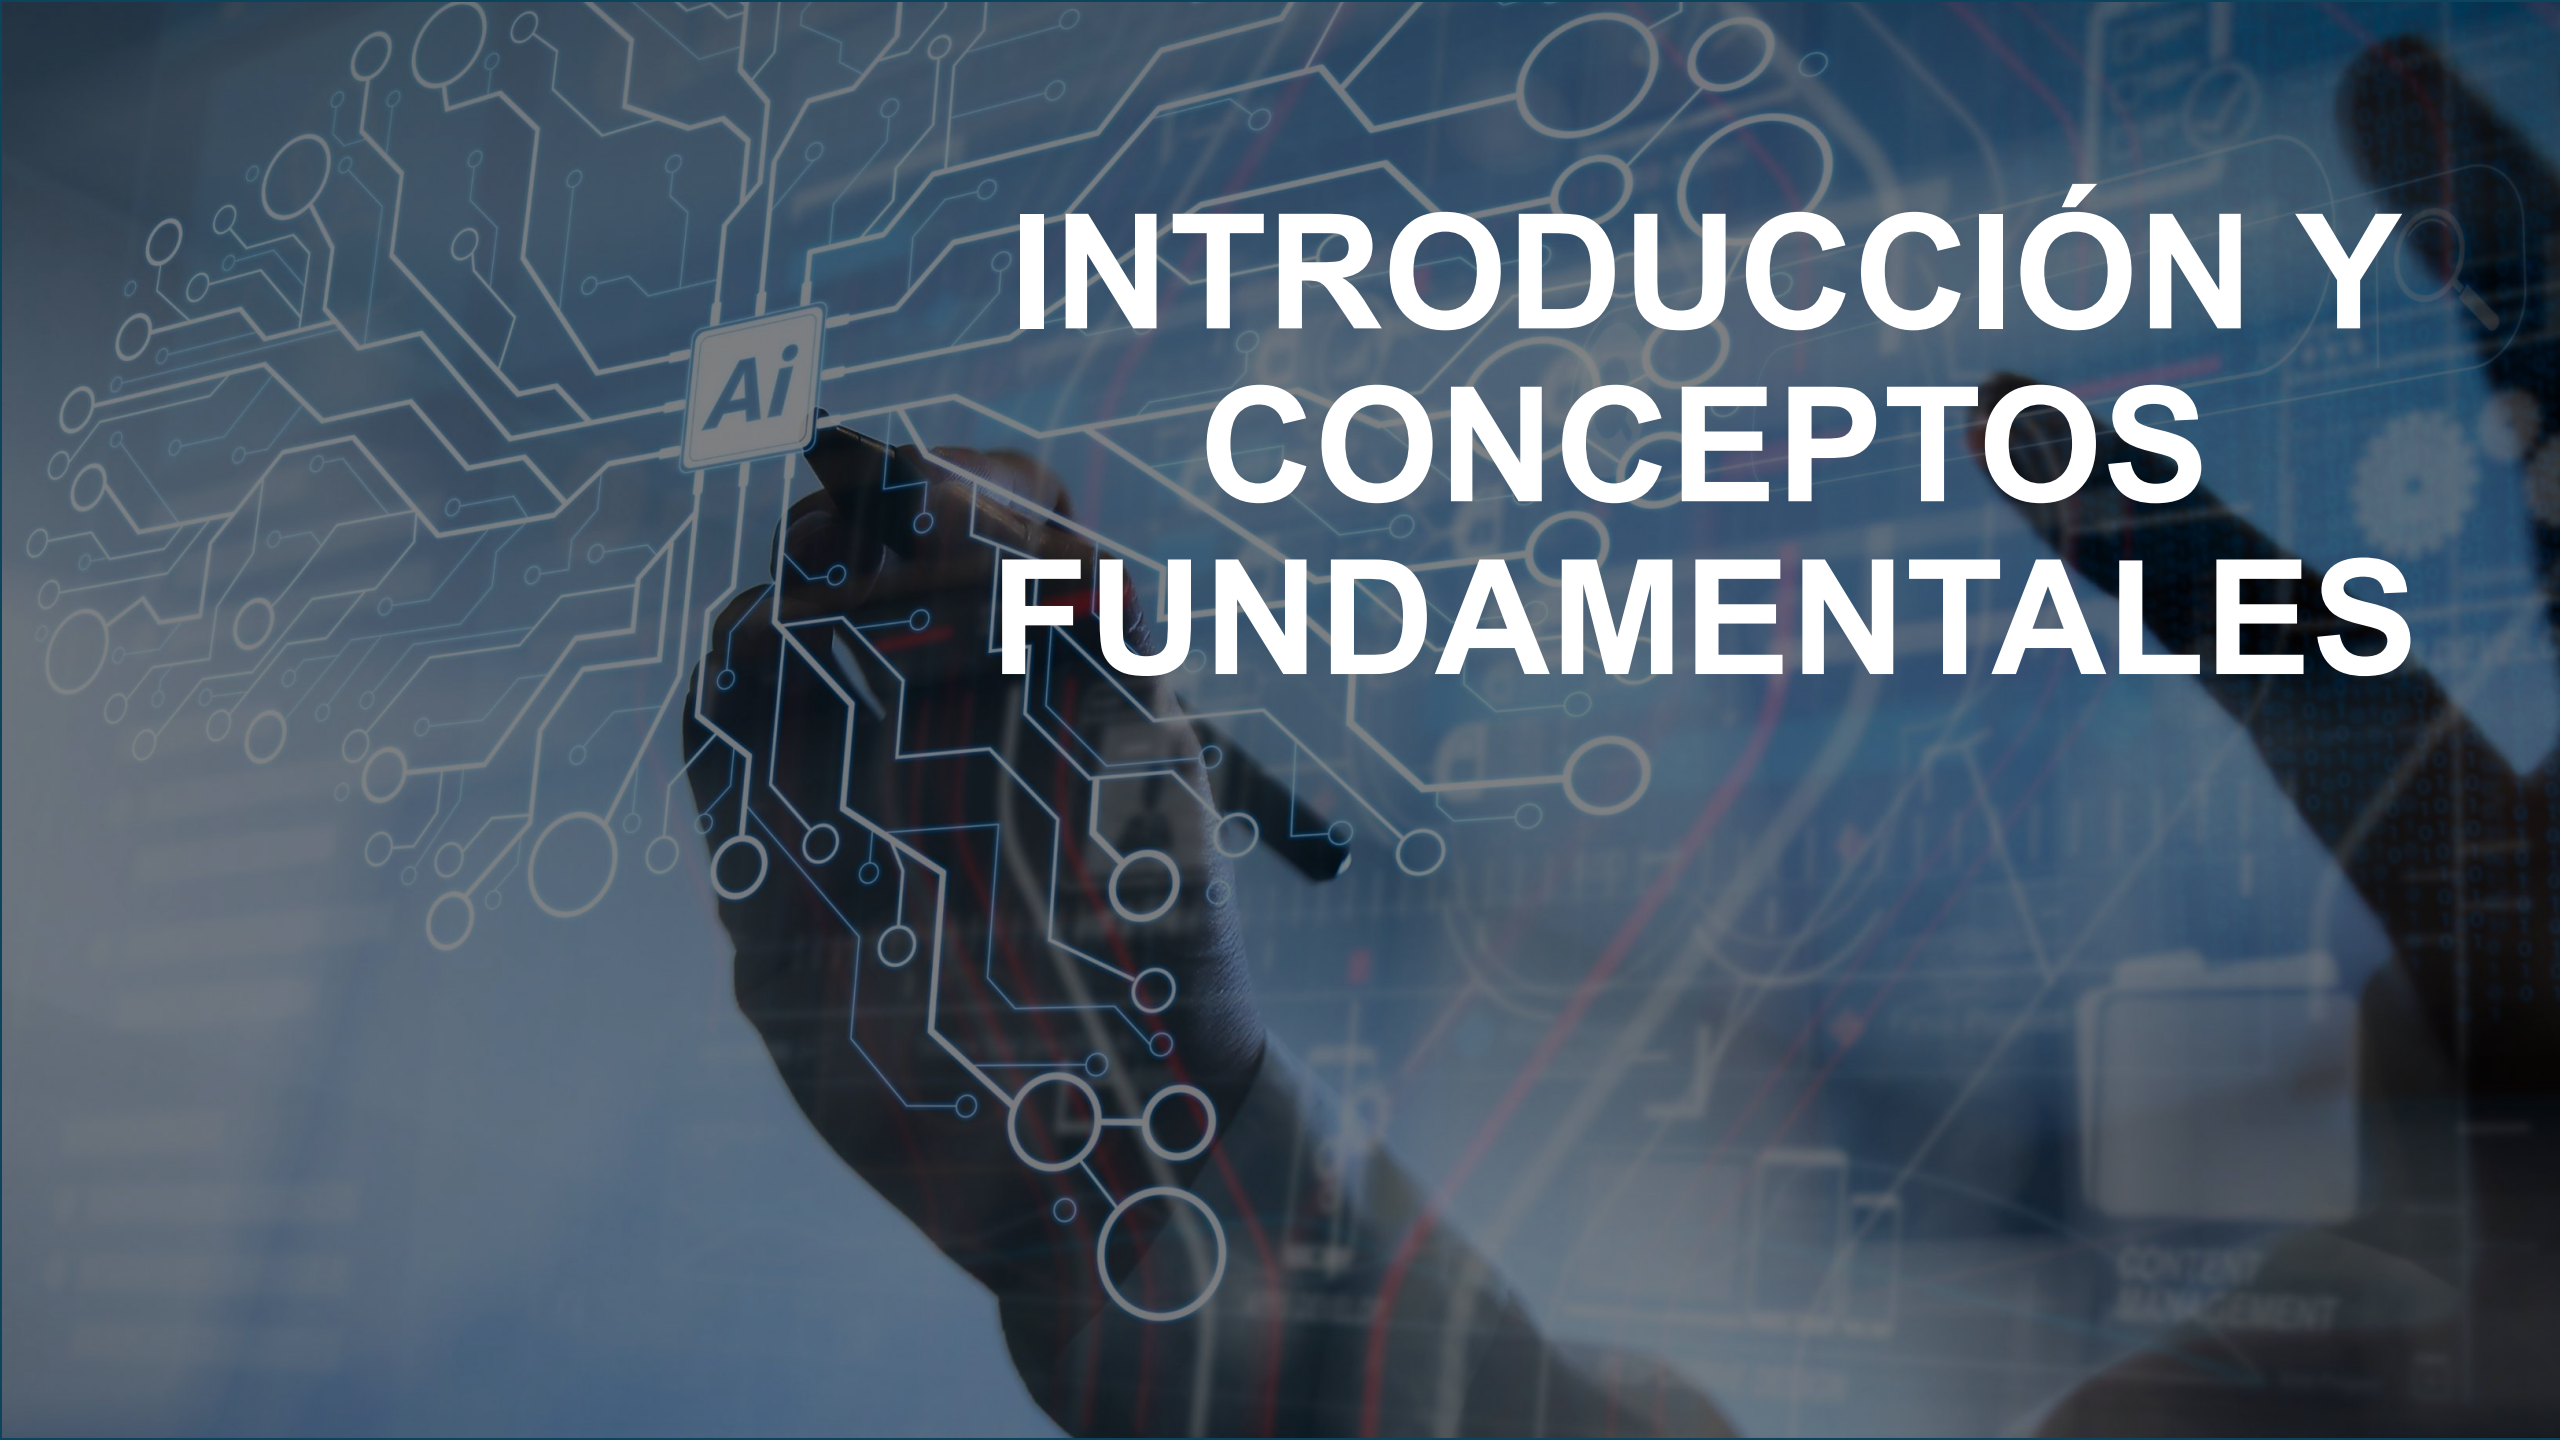
En vez de pedir esto	Pídele esto
Resuélveme el punto 3 del taller.	Explícame qué hace groupby, con otro ejemplo.
Escribe el código para entrenar el modelo.	¿Qué pasos tiene entrenar un modelo? Sin código.
Mi código falla, arréglalo.	¿Qué significa este error y dónde buscarlo?
Hazme el análisis.	Hazme tres preguntas para que lo encuentre yo.

Entonces, ¿la conclusión es no usar IA?

Al contrario. En pocos años va a ser muy difícil competir sin dominar estas herramientas: será como saber usar un computador hace veinte años.

- Dominar es dirigir la herramienta, no aceptar lo primero que sugiere.
- Los cargos de entrada son los primeros en automatizarse: hay que llegar valiendo más que la herramienta.
- Para comandar la herramienta que hace el trabajo, primero hay que entender el trabajo.

Las reglas de este curso son temporales: valen mientras estás aprendiendo lo que después vas a dirigir.

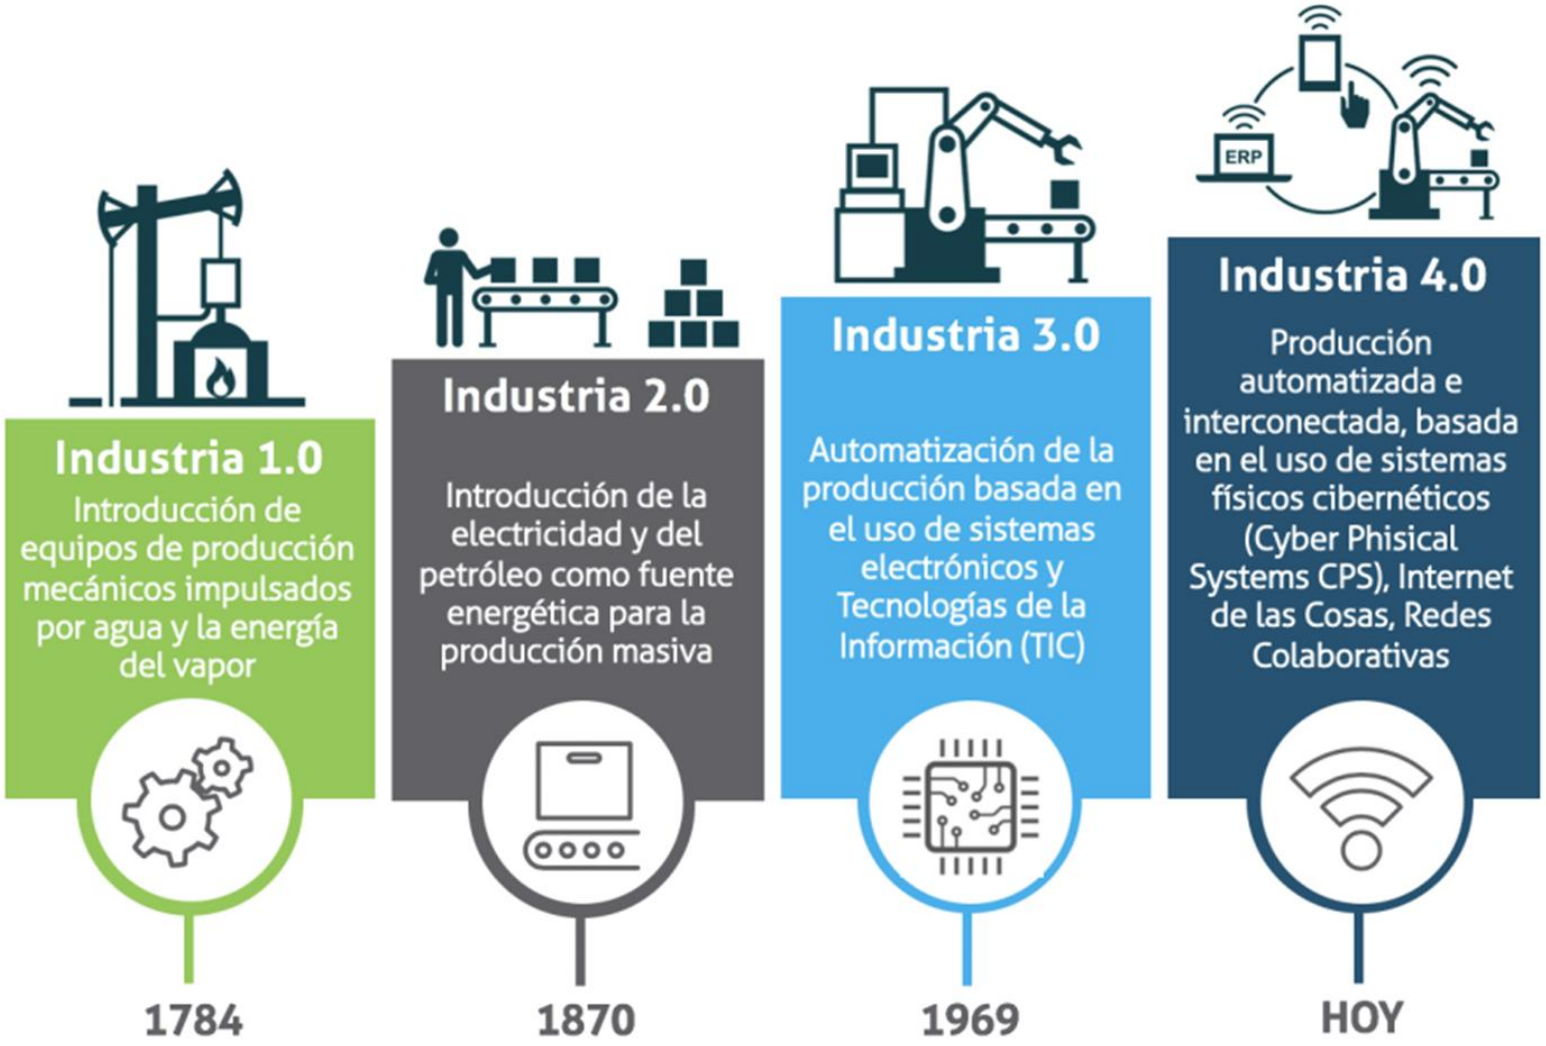


INTRODUCCIÓN Y CONCEPTOS FUNDAMENTALES



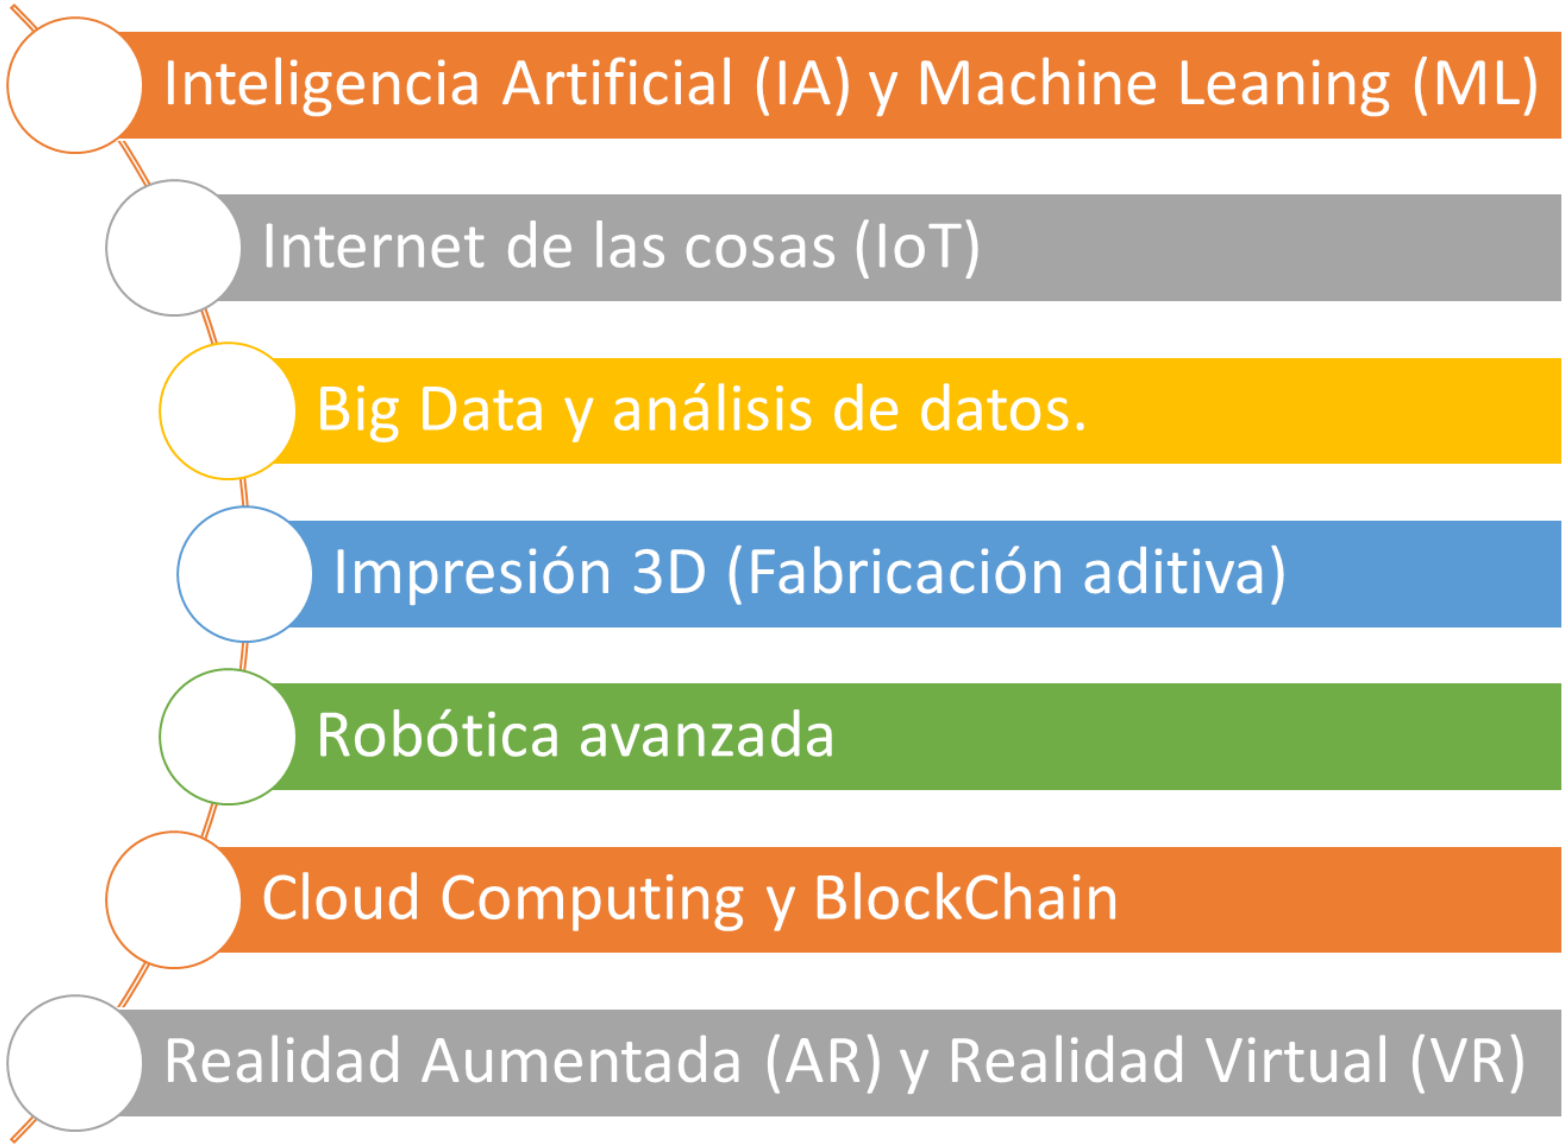
REVOLUCIÓN 4.0

EL MUNDO HA PASADO POR DIFERENTES AVANCES TECNOLÓGICOS



Tomado de: https://www.linkedin.com/pulse/revoluciones-industriales-miguel-due%C3%B1as-arango/

TECNOLOGÍAS CLAVES DE LA REVOLUCIÓN 4.0

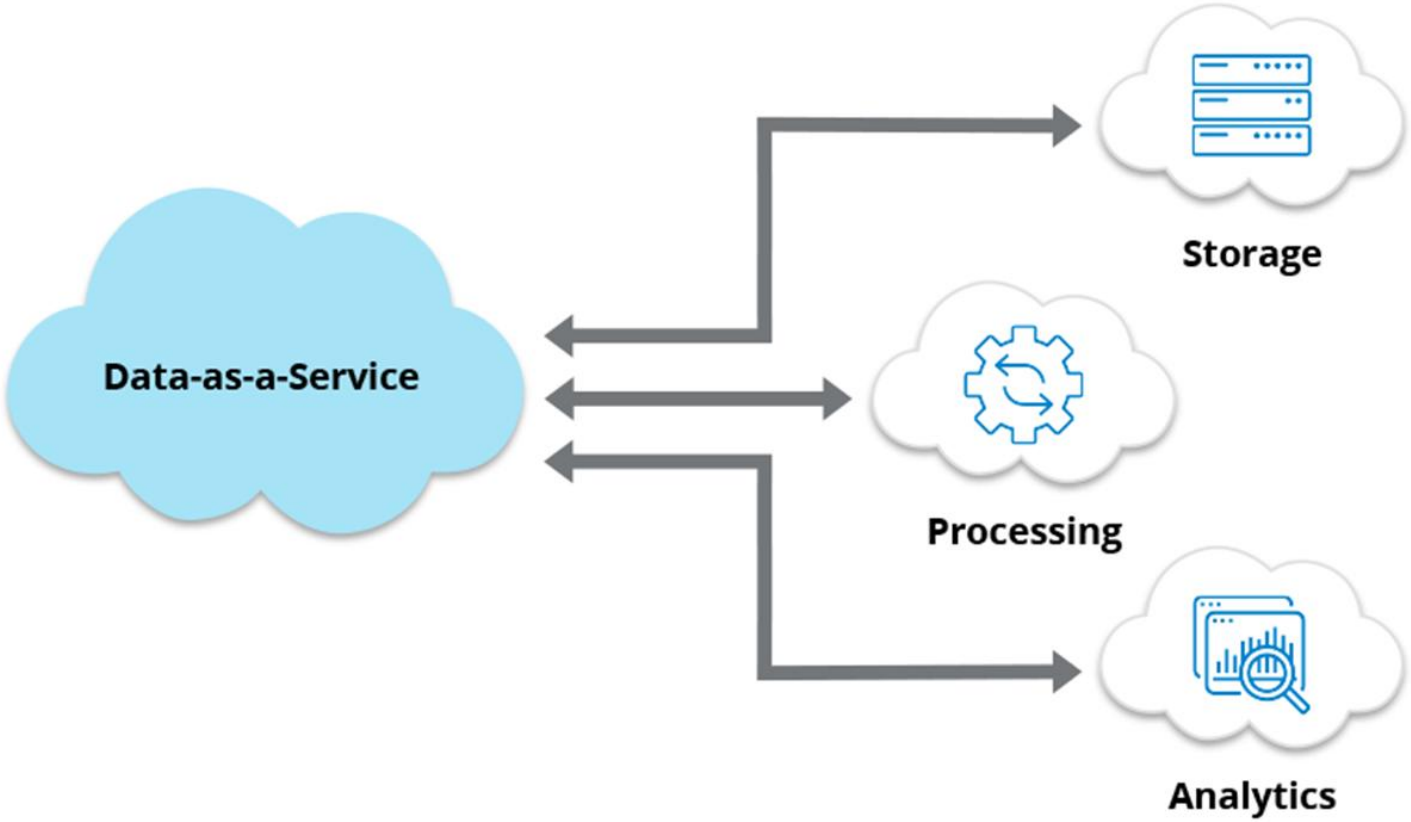


PRINCIPIOS DE LA REVOLUCIÓN 4.0

- Interconexión e interoperabilidad.
- Automatización y robótica.
- Personalización masiva.
- Agilidad, flexibilidad, tiempo real.
- Integración de IA en todo.
- Convergencia de tecnologías
- Reducción de barreras geográficas.

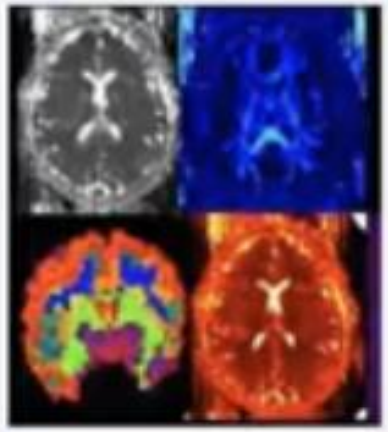
LOS DATOS JUEGAN UN ROL FUNDAMENTAL

La data es el insumo principal para todas las tecnologías de la Revolución 4.0. El análisis y la interpretación de grandes volúmenes de datos permiten **mejorar la toma de decisiones**, **optimizar recursos** y **crear productos y servicios personalizados**.



Tomado de: https://hazelcast.com/glossary/data-as-a-service/

DATA AGE: LA DIGITALIZACIÓN DEL MUNDO



The data-driven world will be **always on**, **always tracking**, **always monitoring**, **always listening** and **always watching – because it will be always learning**.









Uber

Fuente: Reinsel, D.; Gantz, J.; Rydning, J.; (2018) "The Digitization of the World: From Edge to Core", IDC White Paper, #US44413318

DATA AGE: LA DIGITALIZACIÓN DEL MUNDO



Fuente: Reinsel, D.; Gantz, J.; Rydning, J.; (2018) "The Digitization of the World: From Edge to Core", IDC White Paper, #US44413318

LA COMBINACIÓN DE DATOS E IA TRANSFORMA LOS NEGOCIOS

•**Personalización masiva**: Las empresas pueden usar los datos y la IA para ofrecer productos y servicios adaptados a las preferencias individuales de los clientes. Ejemplo: **Netflix** y sus recomendaciones de contenido basadas en el historial de visualización.

•**Optimización de la cadena de suministro**: **Amazon** usa la IA y Big Data para gestionar inventarios y predecir la demanda en tiempo real, mejorando la eficiencia operativa.

•**Mejora en la toma de decisiones**: Las empresas usan la IA para analizar datos en tiempo real y tomar decisiones más rápidas y precisas. Ejemplo: **Tesla** optimiza sus vehículos mediante actualizaciones de software en tiempo real.



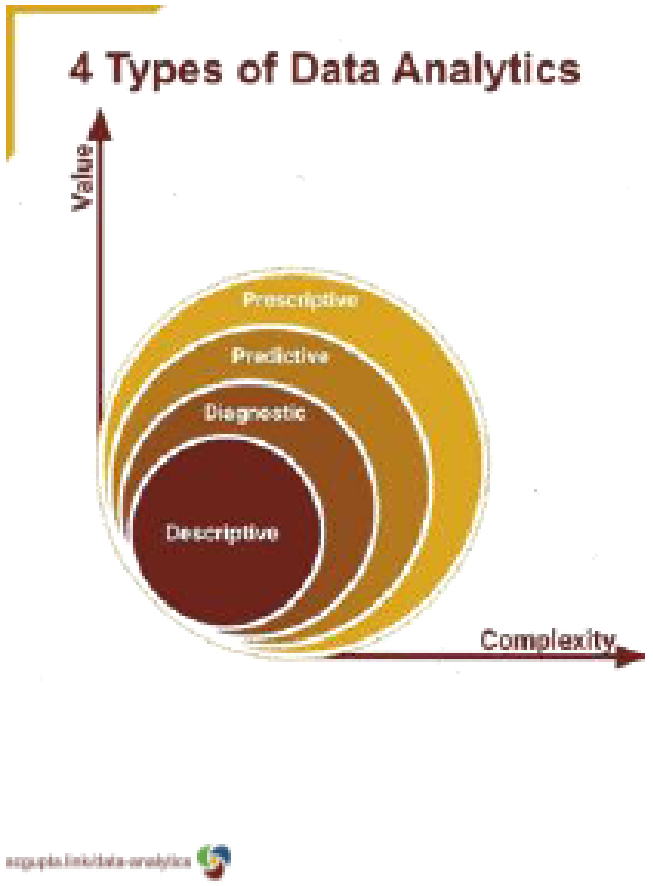
CONCEPTOS BÁSICOS

CIENCIA DE DATOS

- Es una disciplina que **combina estadísticas, programación y conocimiento del dominio** para extraer valor de grandes volúmenes de datos.
- **Involucra todo el ciclo de vida del dato**, desde la recolección y limpieza hasta el análisis, modelado y visualización.
- Utiliza herramientas y lenguajes como **Python, R, SQL, pandas, scikit-learn y más**.
- Permite **descubrir patrones, generar predicciones y tomar decisiones basadas en evidencia.**
- Su foco está en **correlaciones y patrones**, mas que en causalidad**.**
- Transforma los datos en **información y conocimiento.**
- Es **clave en múltiples sectores**, como salud, finanzas, marketing, logística, políticas públicas, entre otros.
- **Relevante en la era digital**, donde los datos son uno de los activos más valiosos para la innovación y la competitividad.



TIPOS DE ANÁLISIS DE DATOS



HINDSIGHT

INSIGHT

FORESIGHT

1.Descriptivo (Descriptive):

1. **Pregunta**: ¿Qué pasó? (Pasado)
2. **Métodos**: Estadísticas descriptivas y Análisis Exploratorio de Datos (EDA), Análisis Ad Hoc.
3. **Propósito**: Proporciona una comprensión básica de los datos y describe lo que ha ocurrido en el pasado.

2.Diagnóstico (Diagnostic):

1. **Pregunta**: ¿Por qué pasó? (Pasado)
2. **Métodos**: Análisis Exploratorio de Datos (EDA), Profundizaciones y descubrimientos.
3. **Propósito**: Examina los datos para entender las causas subyacentes de los eventos y comportamientos observados.

Pasado

3.Predictivo (Predictive):

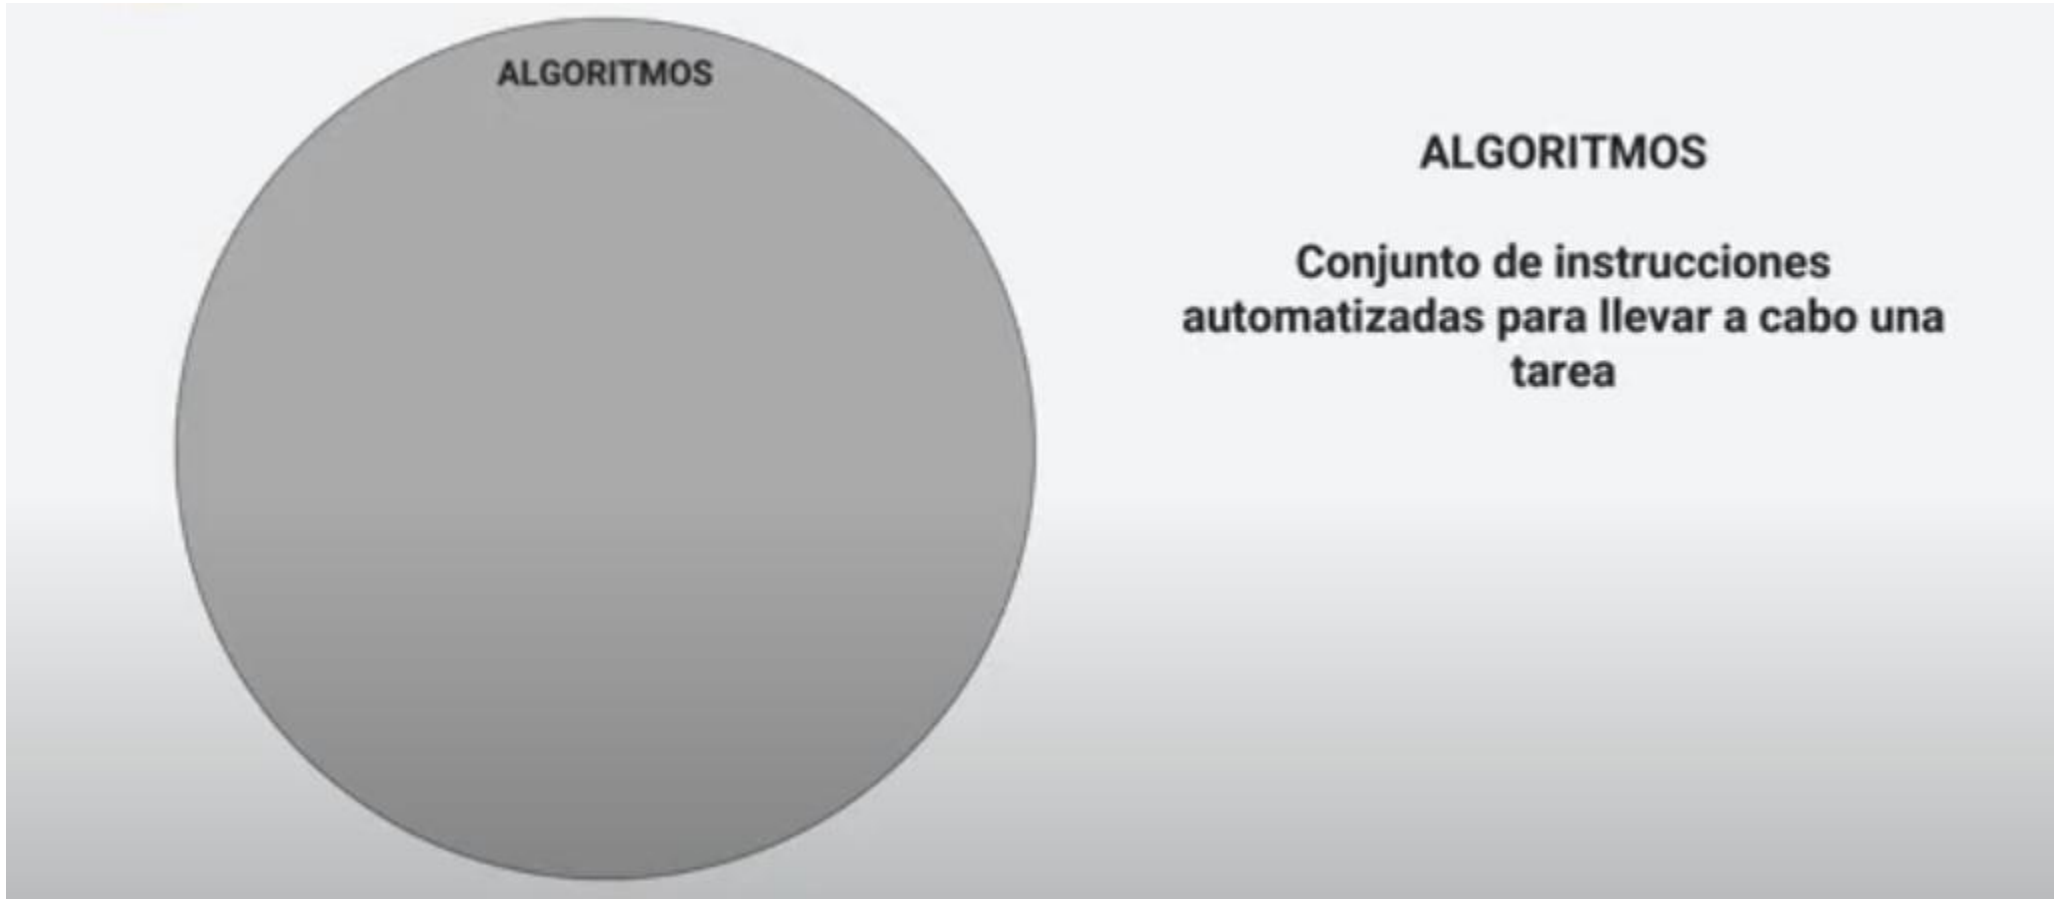
1. **Pregunta**: ¿Qué pasará? (Futuro)
2. **Métodos**: Modelado predictivo y estadístico
3. **Propósito**: Utiliza datos históricos y técnicas estadísticas para predecir eventos y comportamientos futuros.

4.Prescriptivo (Prescriptive):

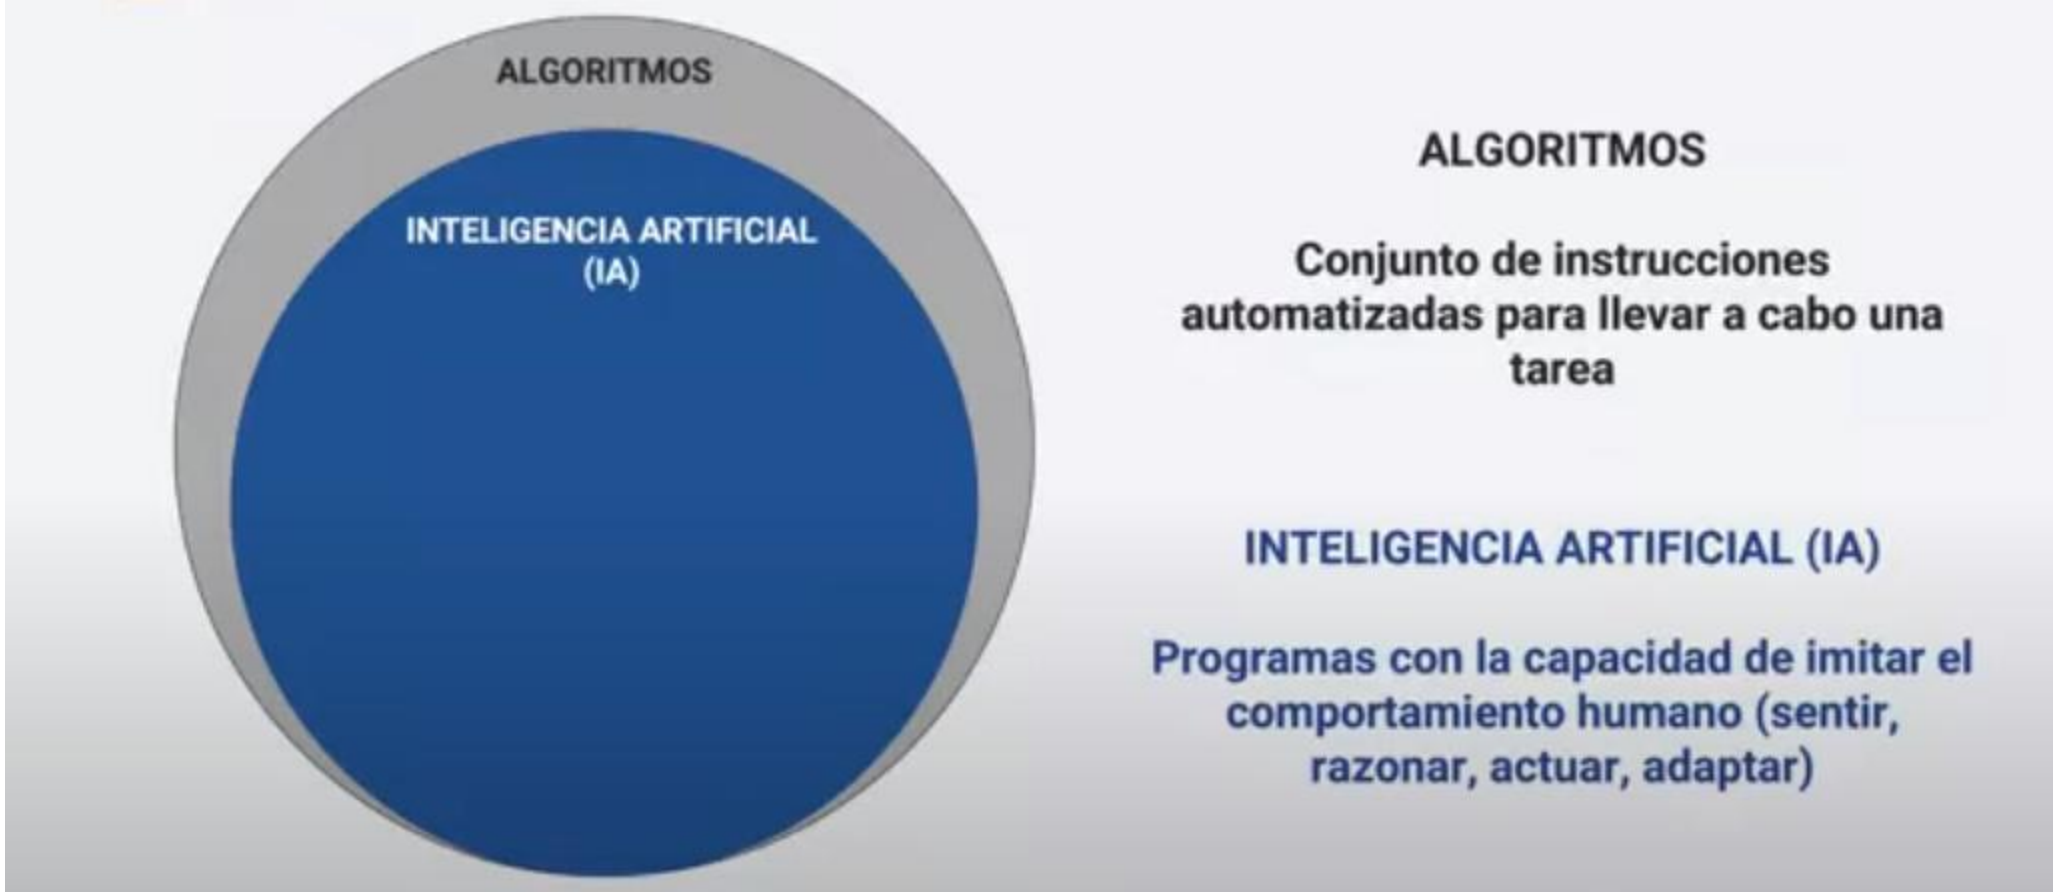
1. **Pregunta**: ¿Qué debo hacer? (Futuro)
2. **Métodos**: Optimización y pruebas aleatorias
3. **Propósito**: Proporciona recomendaciones sobre acciones a tomar para alcanzar objetivos deseados basándose en análisis predictivos y optimización.

Futuro

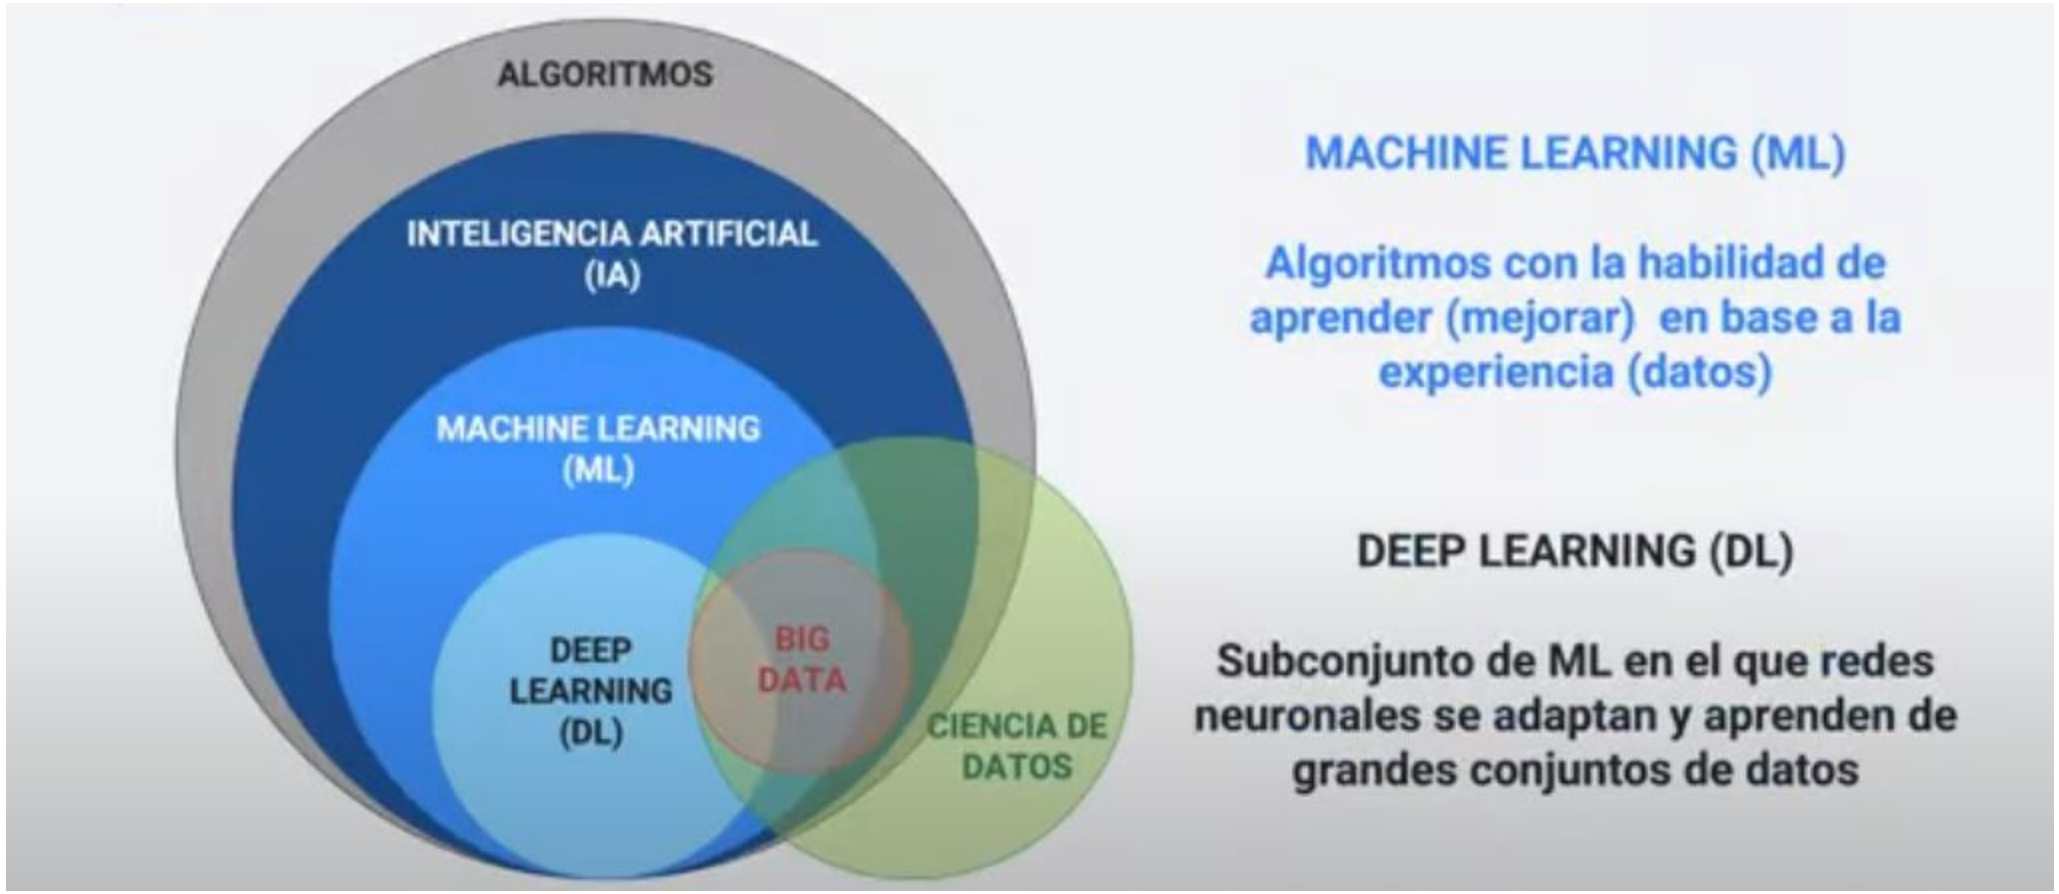
CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



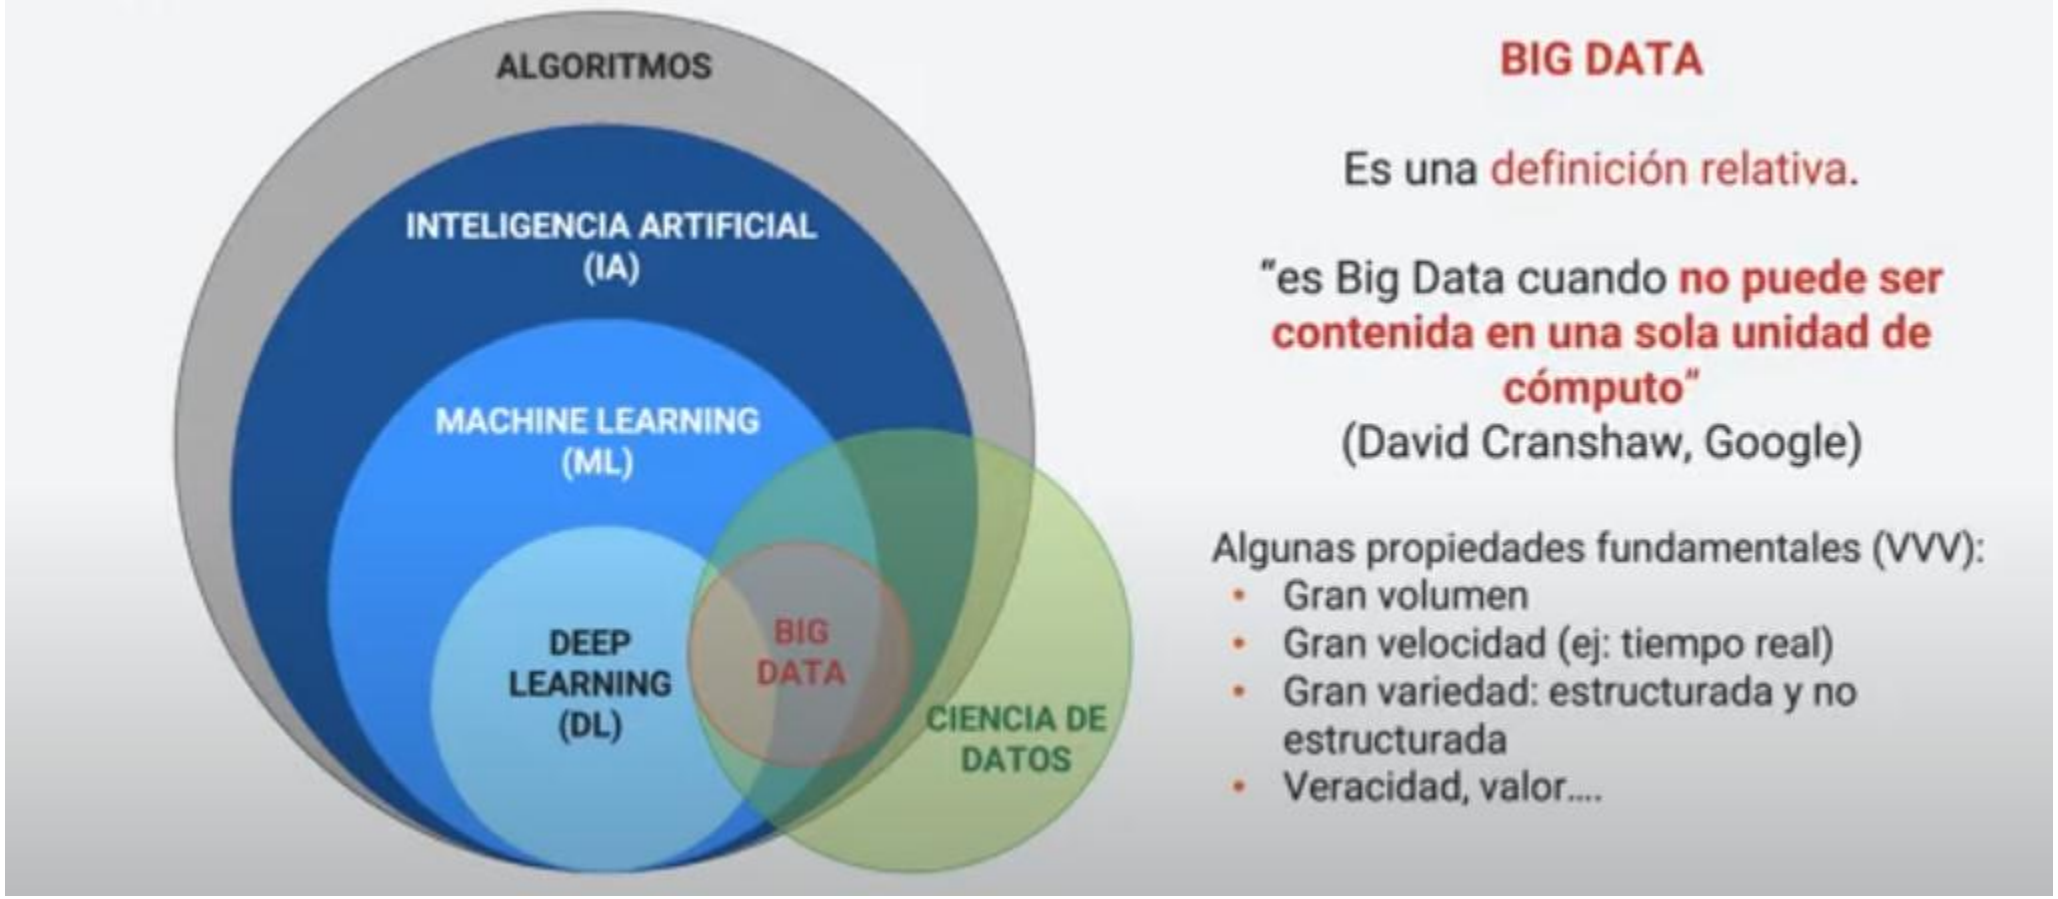
CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

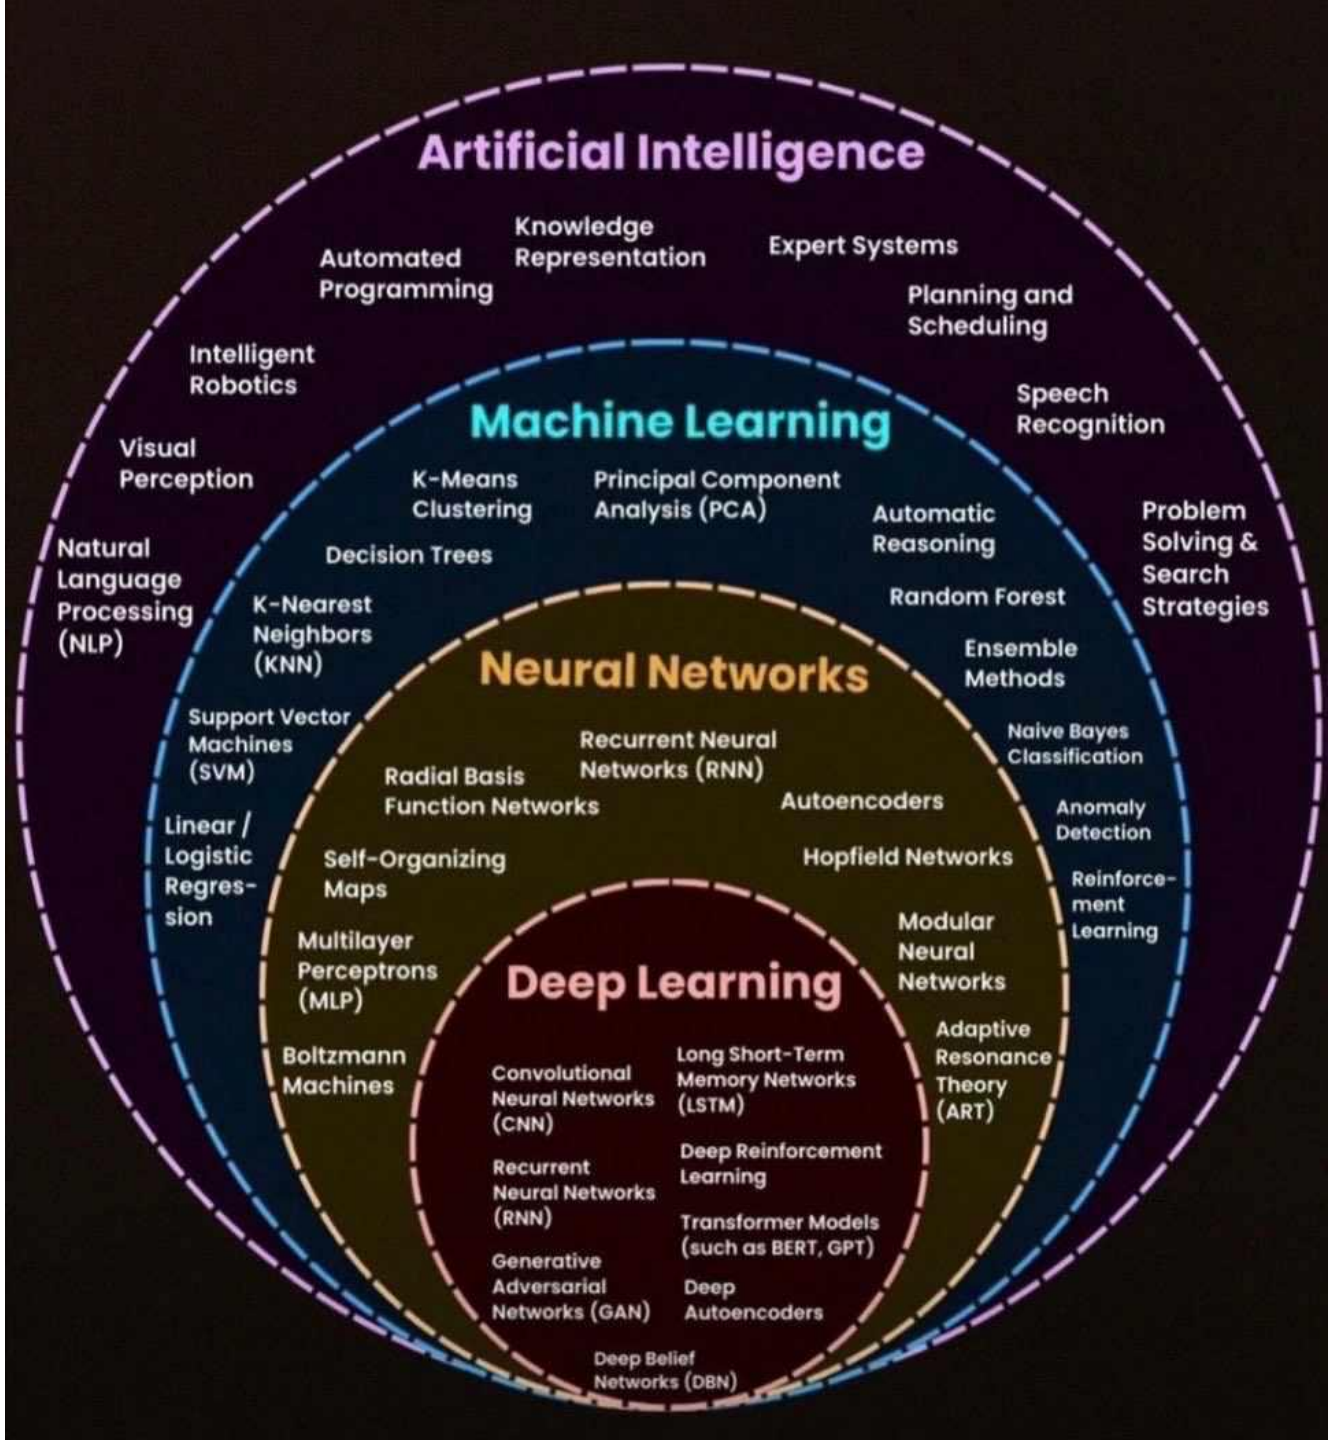


CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



MACHINE LEARNING

Disciplina científica cuyas técnicas permiten a los ordenadores **aprender de forma automática a partir de un conjunto de datos**, de tal forma que sean capaces de hacer predicciones sobre un proceso o describirlo de forma compacta.



MACHINE LEARNING

APRENDIZAJE SUPERVISADO

Algoritmos que permiten inferir, a partir de ejemplos, una función o fórmula matemática que **relacione un conjunto de atributos con una variable de respuesta**. El **objetivo** es **predecir** (generalizar) **la respuesta** ante futuras observaciones de los atributos.

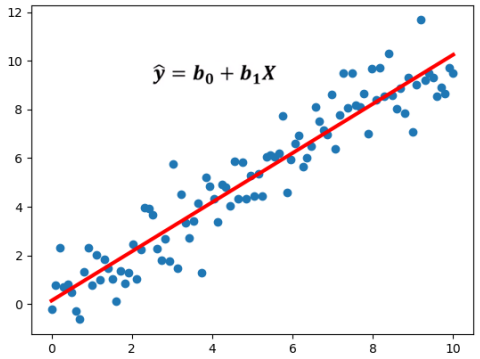
APRENDIZAJE NO SUPERVISADO

Algoritmos que permiten describir cómo están organizados o agrupados un conjunto de datos que **no tienen una variable de respuesta**. El **objetivo** de este método es **conseguir agrupaciones de datos** no detectables a simple vista, **con base en las variables** que describen cada uno de los ejemplos de la muestra.

APRENDIZAJE SUPERVISADO

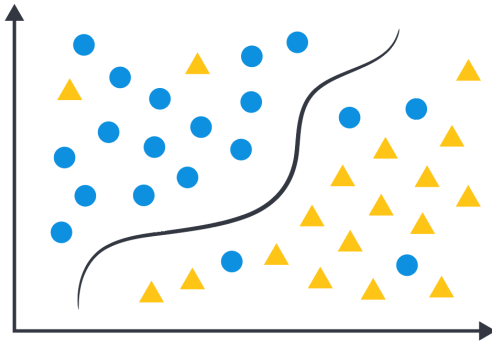
REGRESIÓN

Salario	Nivel de estudios	Sexo	Años de experiencia
$1.000	Bachillerato	M	2
$5.500	Doctorado	F	5
$3.600	Maestría	M	3
$2.800	Pregrado	F	4



CLASIFICACIÓN

Pobre	Nivel de estudios	Sexo	Salario
SI	Bachillerato	M	$1.000
NO	Doctorado	F	$5.500
NO	Maestría	M	$3.600
SI	Primaria	F	$500



ALGUNOS ALGORITMOS DE APRENDIZAJE SUPERVISADO

REGRESIÓN LINEAL

Permite predecir el valor de una variable continua como una función lineal de las variables de entrada.

REGRESIÓN LOGÍSTICA

Permite estimar la probabilidad de que ocurra (o no) un evento como función de las variables de entrada.

KNN

Clasifica puntos según la mayoría de votos de sus K vecinos más cercanos teniendo en cuenta las características o variables de entrada.

ÁRBOLES DE DECISIÓN

Estructura en forma de árbol que toma decisiones basadas en reglas if-then.

RANDOM FOREST

Conjunto de árboles de decisión que se entrenan de manera independiente y cuyas predicciones se combinan.

SUPPORT VECTOR MACHINES

Algoritmo de clasificación que encuentra el hiperplano óptimo que separa las clases teniendo en cuenta las características.

GRADIENT BOOSTING MACHINES

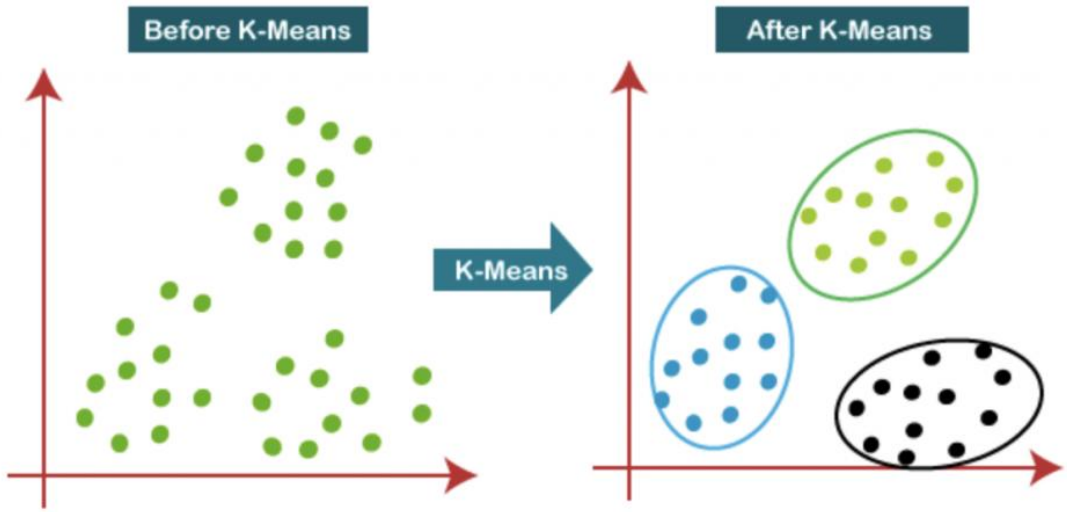
Modelo que construye iterativamente árboles de decisión en serie, cada uno corrigiendo los errores de los anteriores, mejorando el rendimiento en cada iteración.

XGBOOST

Es una implementación avanzada y eficiente de Gradient Boosting, optimizada para mayor velocidad y rendimiento.

APRENDIZAJE NO SUPERVISADO

Cliente	Edad	Sexo	Compras mensuales
Fernando Mora	35	M	$1.000
Andrea Parra	20	F	$5.500
Cristina Ramírez	50	F	$3.600
Juan Gómez	65	M	$2.800



ALGUNOS ALGORITMOS DE APRENDIZAJE NO SUPERVISADO

K-MEANS

Algoritmo de clustering que agrupa un conjunto de datos en K grupos distintos basados en la distancia. Cada punto de datos se asigna al clúster cuyo centroide está más cercano, y los centroides se recalculan iterativamente hasta que las asignaciones de los puntos no cambian.

Aplicaciones: Segmentación de clientes, análisis de patrones.

PCA

Método de reducción de dimensionalidad que transforma los datos a un nuevo sistema de coordenadas donde las nuevas variables (componentes principales) son combinaciones lineales de las variables originales, ordenadas por la varianza que explican. Se utiliza para simplificar los datos mientras se retiene la mayor variabilidad posible.

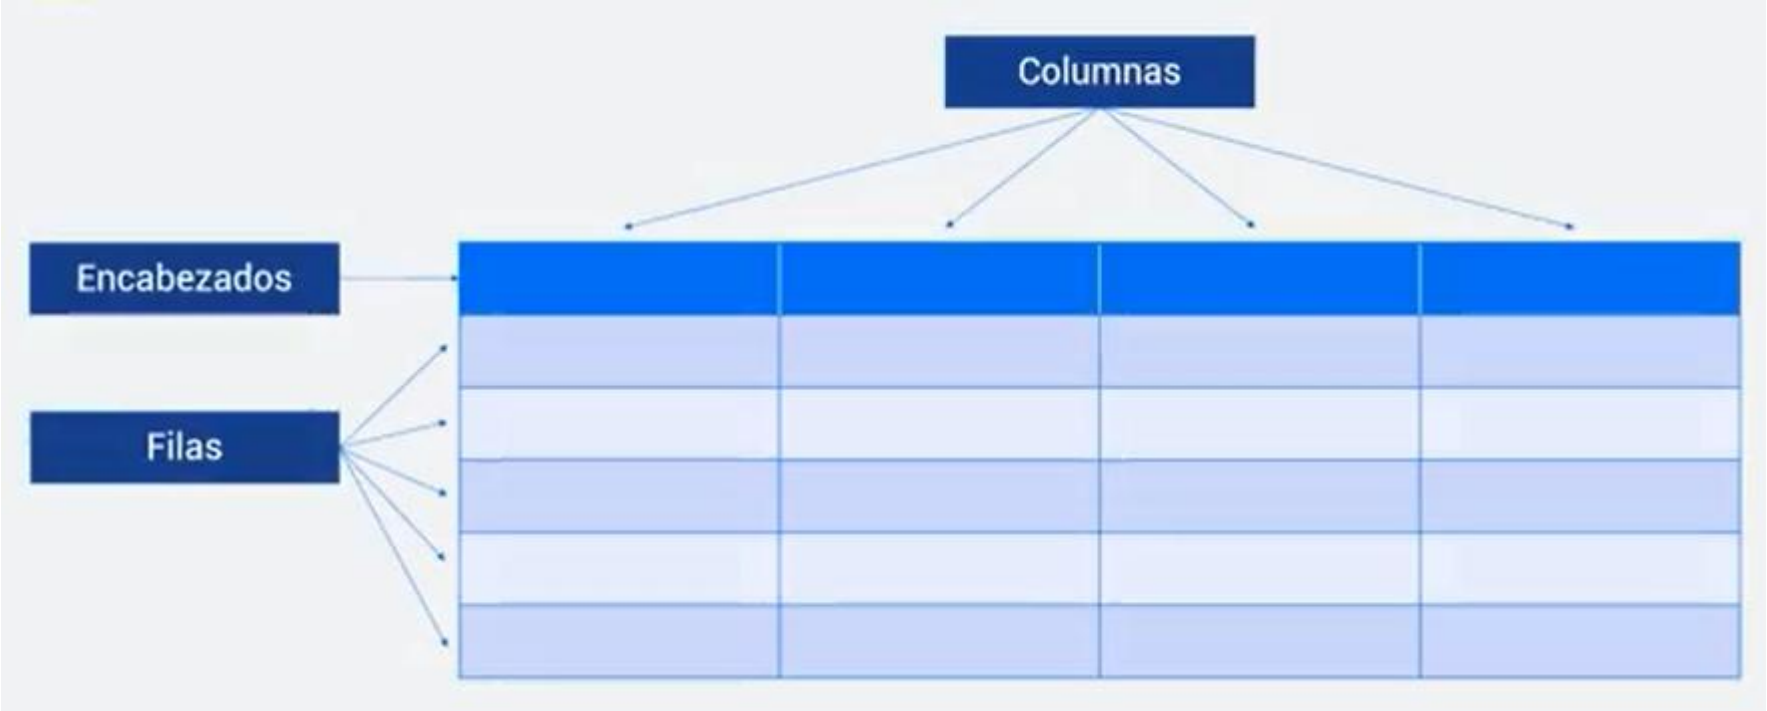
Aplicaciones: Visualización de datos, compresión de datos, preprocesamiento para otros algoritmos.

APRIORI

Algoritmo de reglas de asociación que se utiliza para descubrir relaciones entre variables en grandes conjuntos de datos. Busca conjuntos frecuentes de ítems y genera reglas que describen relaciones entre los ítems.

Aplicaciones: Análisis de cestas de compra, detección de patrones en transacciones, recomendadores de productos.

DATOS ESTRUCTURADOS



Archivos de texto simple

Planillas de cálculo

Bases de datos relacionales

DATOS SEMIESTRUCTURADOS

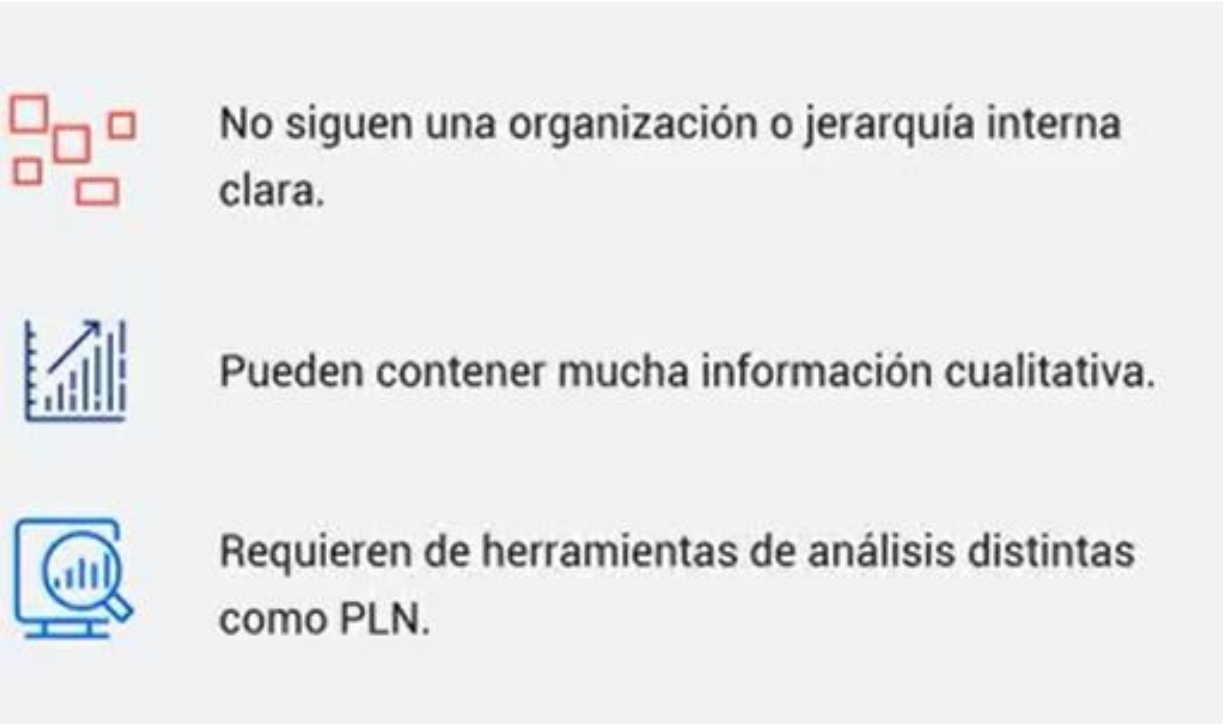
Los **datos semiestructurados** cuentan con una organización jerárquica, a partir de llaves y etiquetas semánticas.

Ejemplo formato JSON

JavaScript Object Notation

```
{
    'nombre': 'Luis',
    'apellido': 'Perez',
    'mail': 'luisperez@mail.com',
    'comprasMes': 178540
},
{
    'nombre': 'Victoria',
    'apellido': 'Solar',
    'mail': 'vsolar@mail.com',
    'compras': {'Cuaderno cuadros':5,'Lapiz grafito':10,'Goma de borrar':8},
    'telefono':'5687654325'
}
```

DATOS NO ESTRUCTURADOS



Ejemplos:

- Audios
- Imágenes
- Documentos
- Comentarios en redes sociales



HERRAMIENTAS ANALÍTICAS

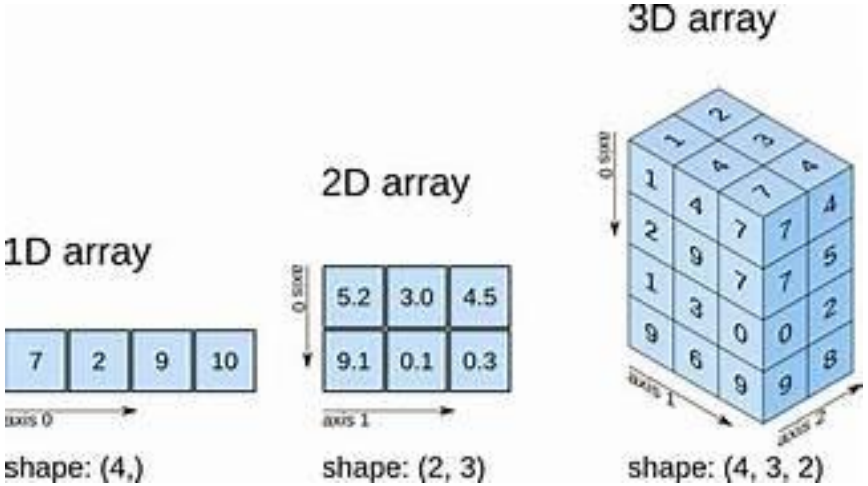
PYTHON (www.python.org)

- Es un **lenguaje de programación interpretado**, de alto nivel y fácil de aprender, con una sintaxis clara y legible. Los comandos o instrucciones se ejecutan paso por paso.
- **Es multipropósito**, usado en desarrollo web, automatización, análisis de datos, inteligencia artificial, entre otros.
- Cuenta con una **amplia y activa comunidad y miles de bibliotecas**, lo que acelera el desarrollo de proyectos complejos.
- **Relevante en ciencia de datos y machine learning** por su versatilidad, facilidad de integración y herramientas especializadas.



NUMPY (numpy.org)

- Es una **biblioteca fundamental de Python para el cálculo numérico y científico**.
- **Proporciona arreglos multidimensionales (ndarrays)** y funciones eficientes para operar sobre grandes volúmenes de datos.
- **Optimiza el rendimiento** en operaciones matemáticas complejas gracias a su implementación en C.
- **Provee las estructuras**, algoritmos y funciones para la mayoría de las aplicaciones científicas relacionadas con datos numéricos.
- **Es la base de otras bibliotecas** como pandas, scikit-learn y TensorFlow, lo que la hace esencial en ciencia de datos y machine learning.



PANDAS (pandas.pydata.org)

- Es una **biblioteca de Python especializada en la manipulación y análisis de datos estructurados y tablas**.
- **Ofrece estructuras como DataFrame y Series**, que facilitan el manejo de datos tabulares y temporales.
  - **Dataframe:** estructura de datos tabular con etiquetas de filas y columnas.
  - **Series:** objeto tipo arreglo 1-D con etiqueta.
- **Permite leer, limpiar, transformar y exportar datos** de manera eficiente desde múltiples fuentes (CSV, Excel, SQL, etc.).
- **Combina la eficiencia de cálculo de NumPy con** capacidades de manipulación de datos típicas de **hojas de cálculo** como Excel y bases de datos relacionales.
- Es **fundamental en ciencia de datos y análisis**, por su facilidad de uso y su integración con otras bibliotecas como NumPy, Matplotlib y Scikit-learn.



Series

	peppers
0	3
1	2
2	0
3	1

+

Series

	carrots
0	0
1	3
2	7
3	2

=

DataFrame

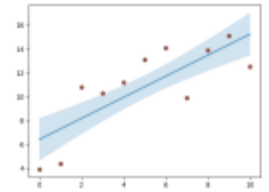
	peppers	carrots
0	3	0
1	2	3
2	0	7
3	1	2

MATPLOTLIB (matplotlib.org)

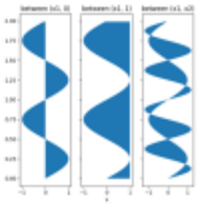
- Es una **biblioteca de Python para crear gráficos** y visualizaciones de datos 2D/3D.
- **Permite generar gráficos variados,** como líneas, barras, histogramas, dispersión, entre otros.
- **Altamente personalizable**, ideal para crear visualizaciones profesionales y adaptadas a distintas necesidades.
- **Relevante en análisis de datos**, ya que facilita la comprensión de patrones y tendencias en los datos.
- **Librería base para otras interfaces de ploteo de alto nivel** como Seaborn (gráficos estadísticos) o Plotly (gráficos interactivos).



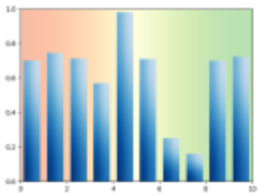
Rellenar entre y alfa

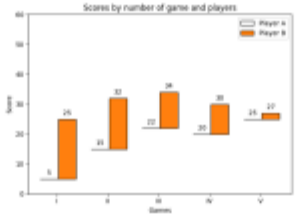


Llenar el área entre líneas



Demostración de relleno de Betweenx



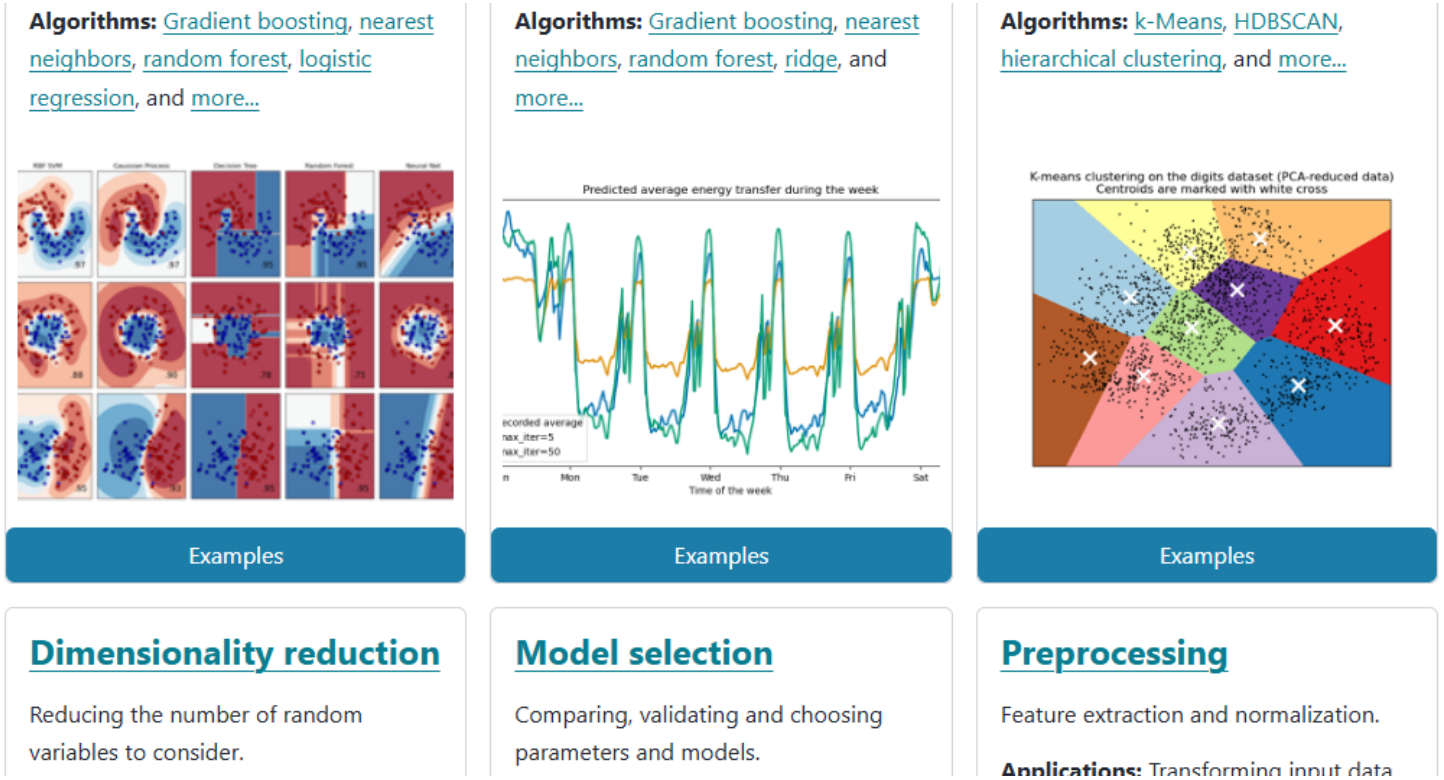




matplotlib

SCIKIT-LEARN (scikit-learn.org)

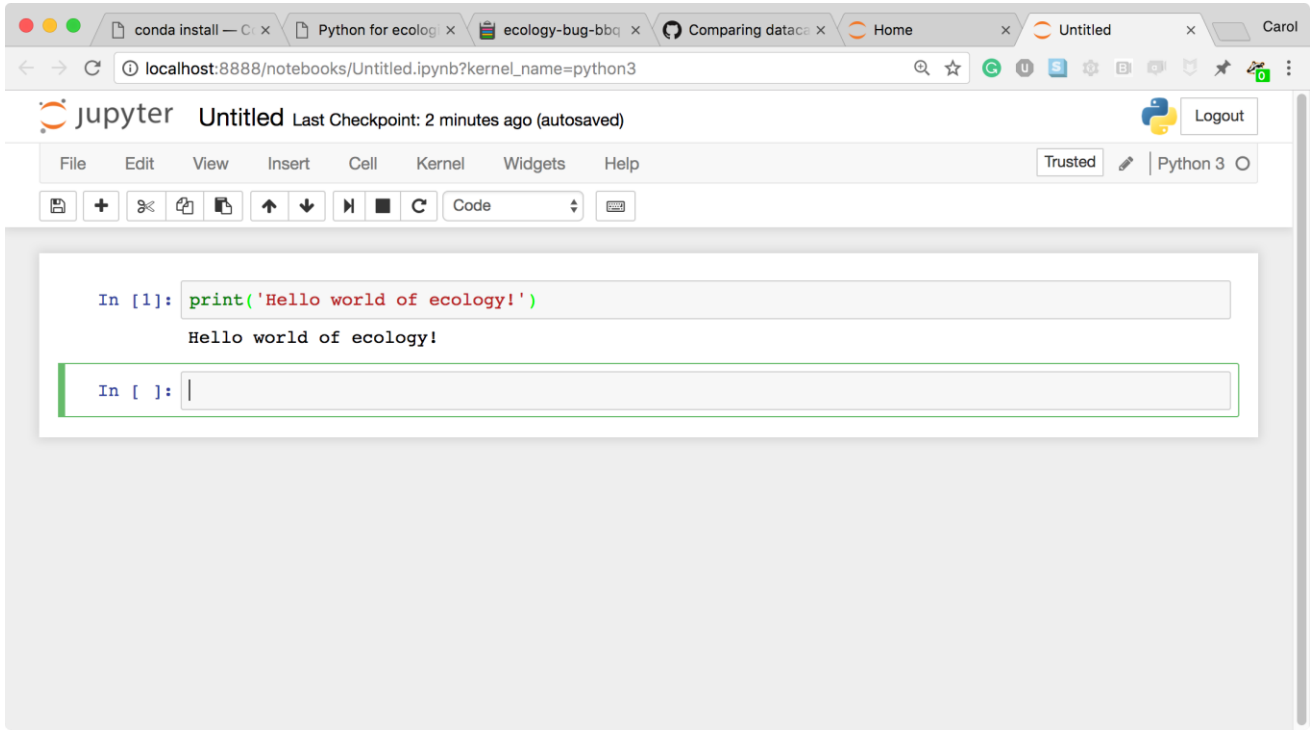
- Es una **biblioteca de Python** de código abierto **para machine learning** y análisis de datos.
- **Ofrece herramientas simples y eficientes** para tareas como clasificación, regresión, clustering y reducción de dimensionalidad.
- **Fácil de usar e integrar** con otras bibliotecas como NumPy, pandas y matplotlib.
- **Relevante en ciencia de datos** por su amplia adopción, documentación clara y utilidad en proyectos tanto académicos como industriales.



scikit learn
machine learning in Python

JUPYTER NOTEBOOKS (jupyter.org)

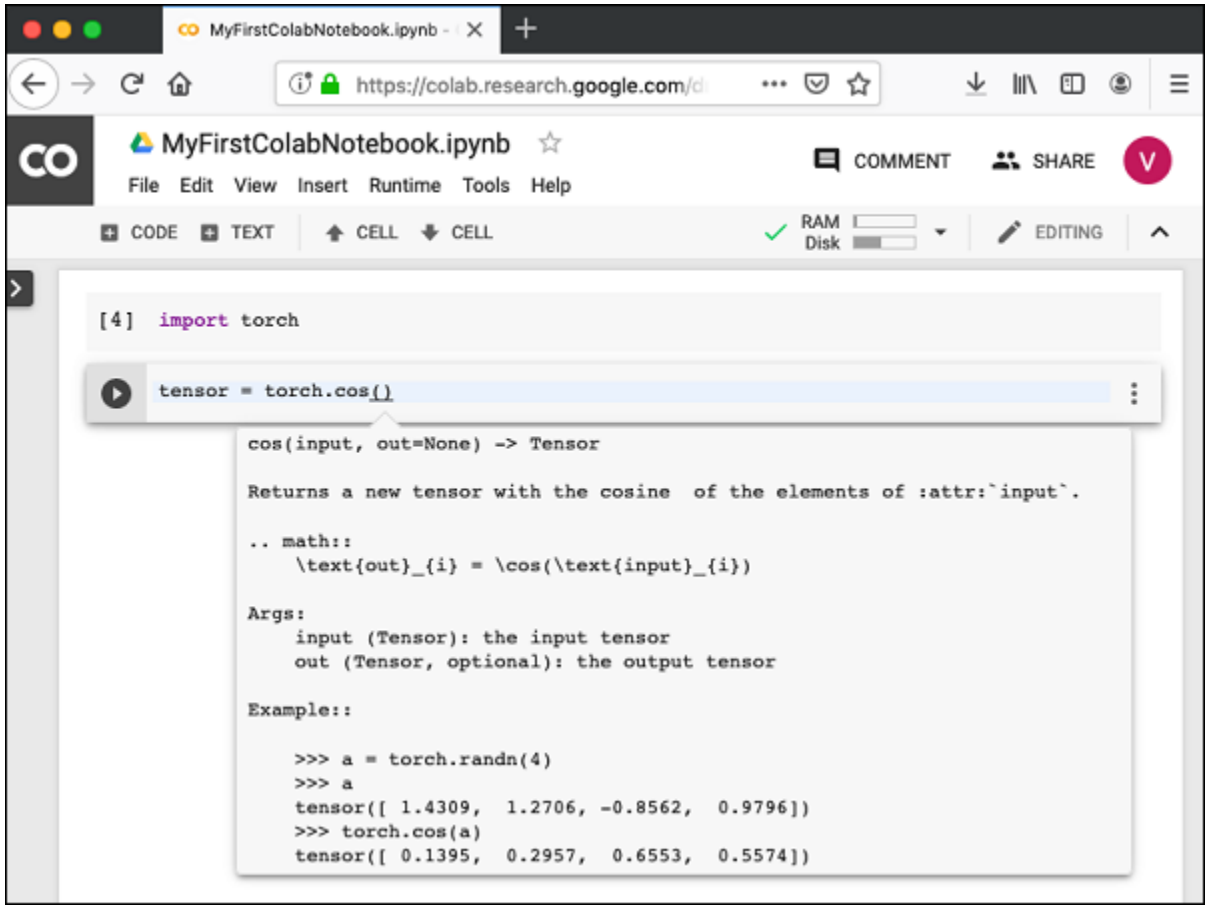
- Es una **aplicación web** que permite crear y compartir documentos con código en vivo, visualizaciones y texto explicativo.
- **Soporta varios lenguajes de programación** (R, Julia, JavaScript, SQL, C++, tec) aunque es más comúnmente usado con Python para análisis de datos y machine learning.
- **Facilita el desarrollo interactivo**, permitiendo ejecutar bloques de código por separado y ver resultados inmediatos.
- **Ideal para investigación, educación y ciencia de datos**, ya que combina código, gráficos y documentación en un solo entorno.





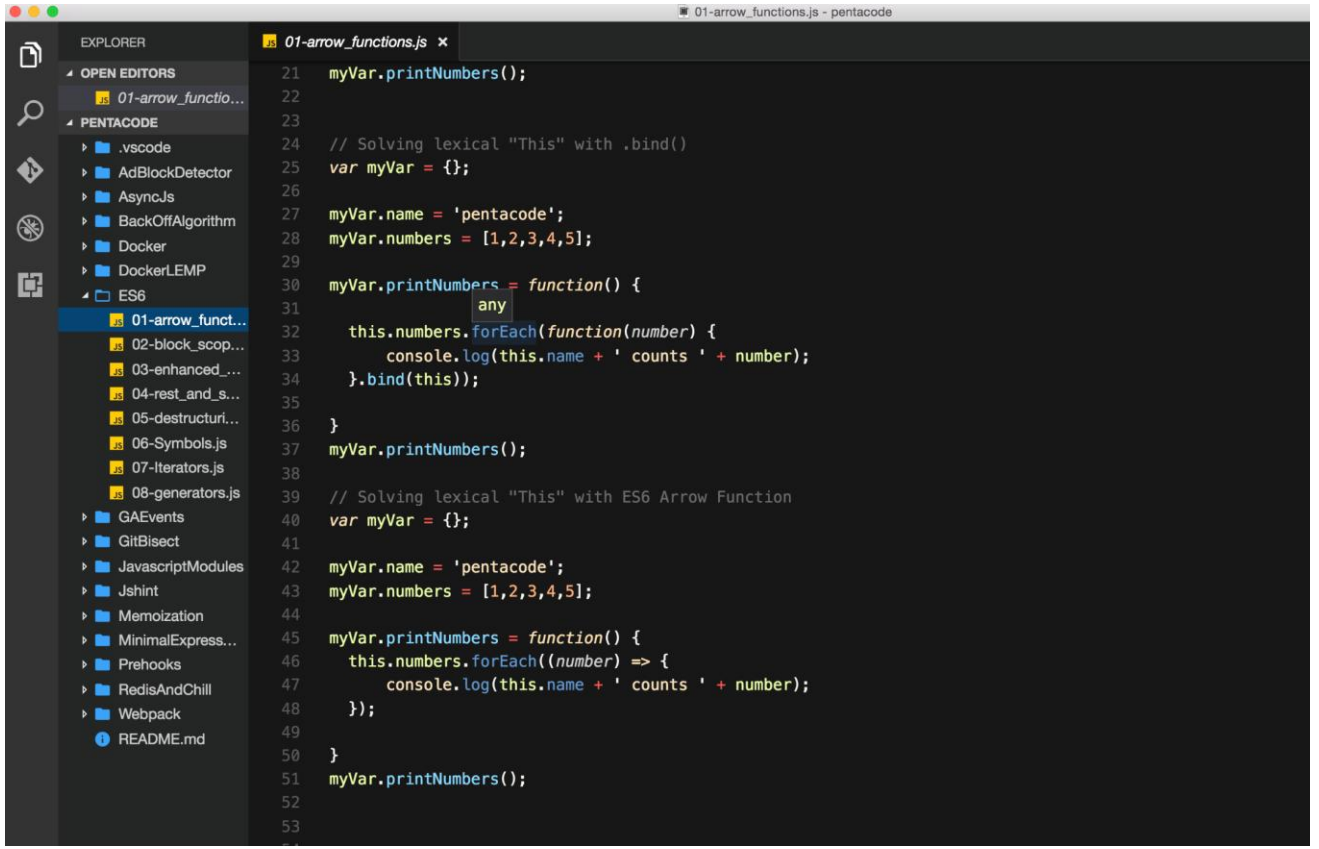
GOOGLE COLAB (colab.research.google.com)

- Es una **plataforma gratuita basada en la nube** que permite escribir y ejecutar código en Python directamente desde el navegador.
- **No requiere instalación**, ya que funciona con notebooks de Jupyter almacenados en Google Drive.
- **Incluye acceso a GPUs y TPUs gratuitas**, lo que facilita el desarrollo de proyectos de machine learning y análisis de datos.
- Ideal para colaborar, ya que **permite compartir notebooks fácilmente** y trabajar en equipo, aunque no en tiempo real.



VISUAL STUDIO CODE (code.visualstudio.com)

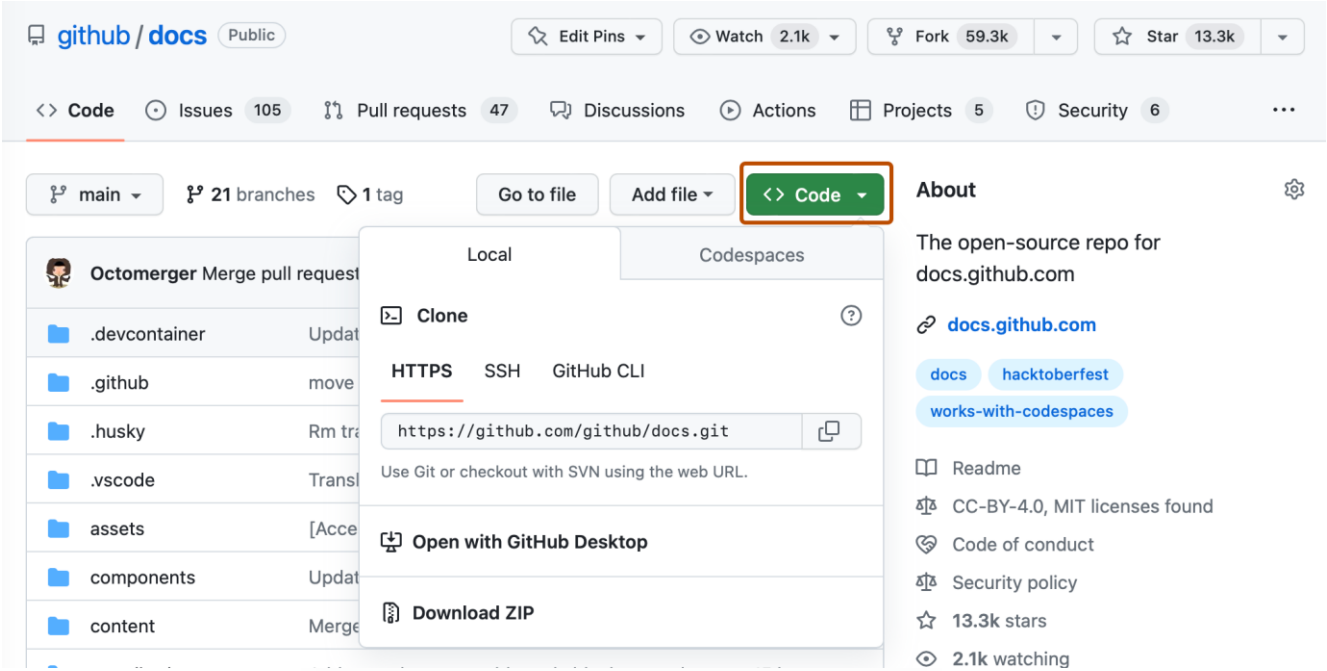
- Es un **editor de código fuente gratuito**, ligero y multiplataforma desarrollado por Microsoft.
- **Soporta múltiples lenguajes de programación**, como Python, JavaScript, HTML, C++, entre otros.
- **Ofrece herramientas integradas** como depuración, control de versiones (Git) y terminal, lo que mejora la productividad del desarrollador.
- Es **altamente personalizable** mediante extensiones, temas y configuraciones para adaptarse a distintos proyectos y flujos de trabajo.



Visual Studio Code

GIT Y GITHUB (github.com)

- **Git** es un **sistema de control de versiones** que permite llevar un seguimiento de los cambios en el código y trabajar en equipo sin perder historial.
- **GitHub** es una **plataforma en la nube que aloja repositorios Git** y facilita la colaboración entre desarrolladores.
- **Permiten trabajar de forma organizada y segura**, integrando funciones como ramas, revisiones de código y control de versiones.
- **Relevantes para cualquier proyecto de desarrollo**, ya que mejoran la productividad, la colaboración y el manejo de versiones del software.





REPRODUCIBILIDAD CIENTÍFICA

Capacidad de reproducir procedimientos científicos (experimentos, análisis, resultados).

¿Por qué es importante?

- Para repetir un análisis con distintos parámetros.
- Para escalar un análisis y entregarlo a equipo de producción.
- Para crear confianza en los resultados.
- Para compartir el conocimiento.

¿Cómo lo hacemos?

- Disponibilización de datos.
- Automatización de procesos, sin pasos “manuales”.
- Desarrollando procesos computaciones transparentes.
- Usando modelos y herramientas eficientes de reusabilidad (Ejemplo: software abierto, notebooks, repositorios).



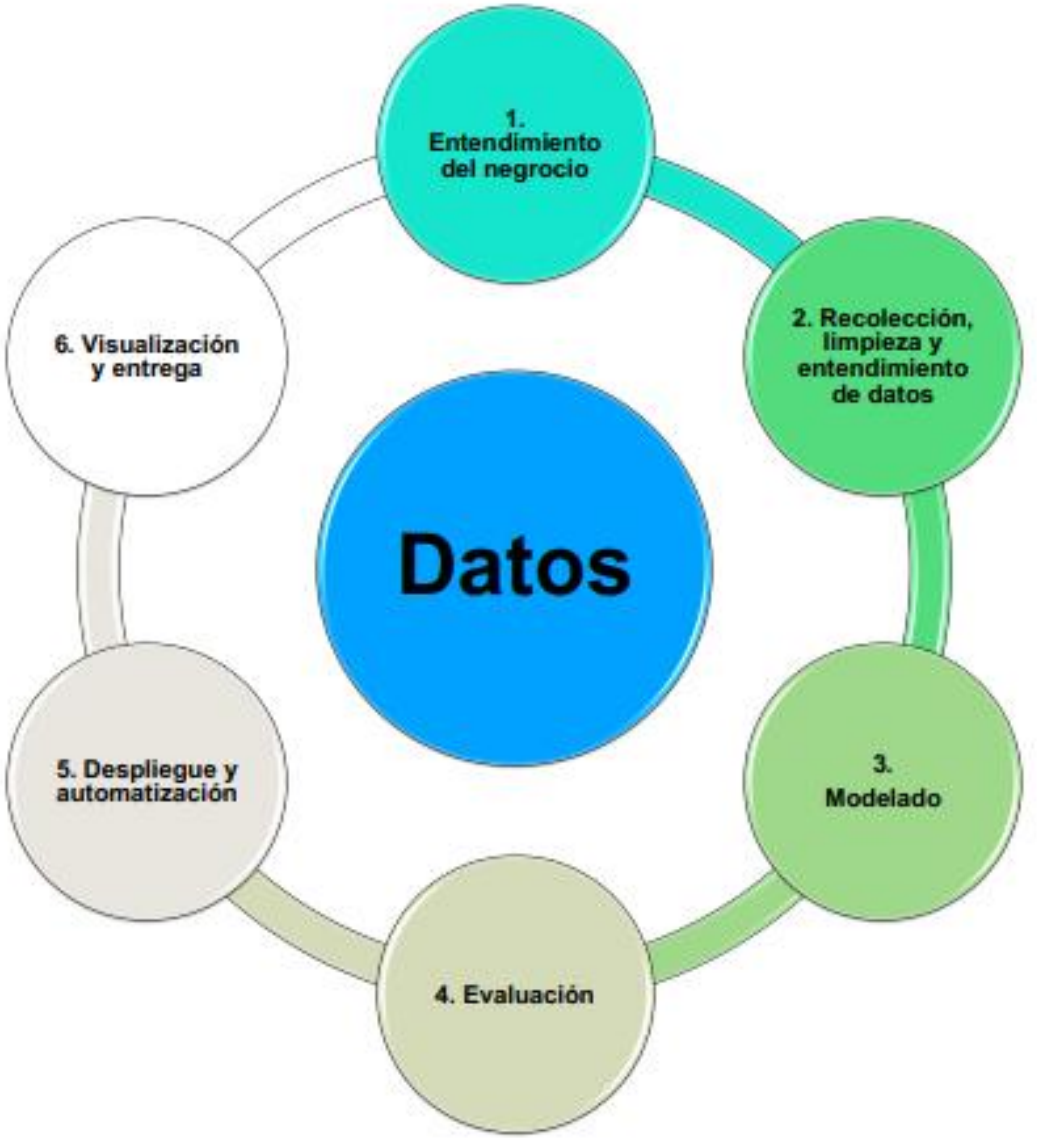
¿CÓMO SE DESARROLLA UN PROYECTO ANALÍTICO?

METODOLOGÍA CRISP-DM

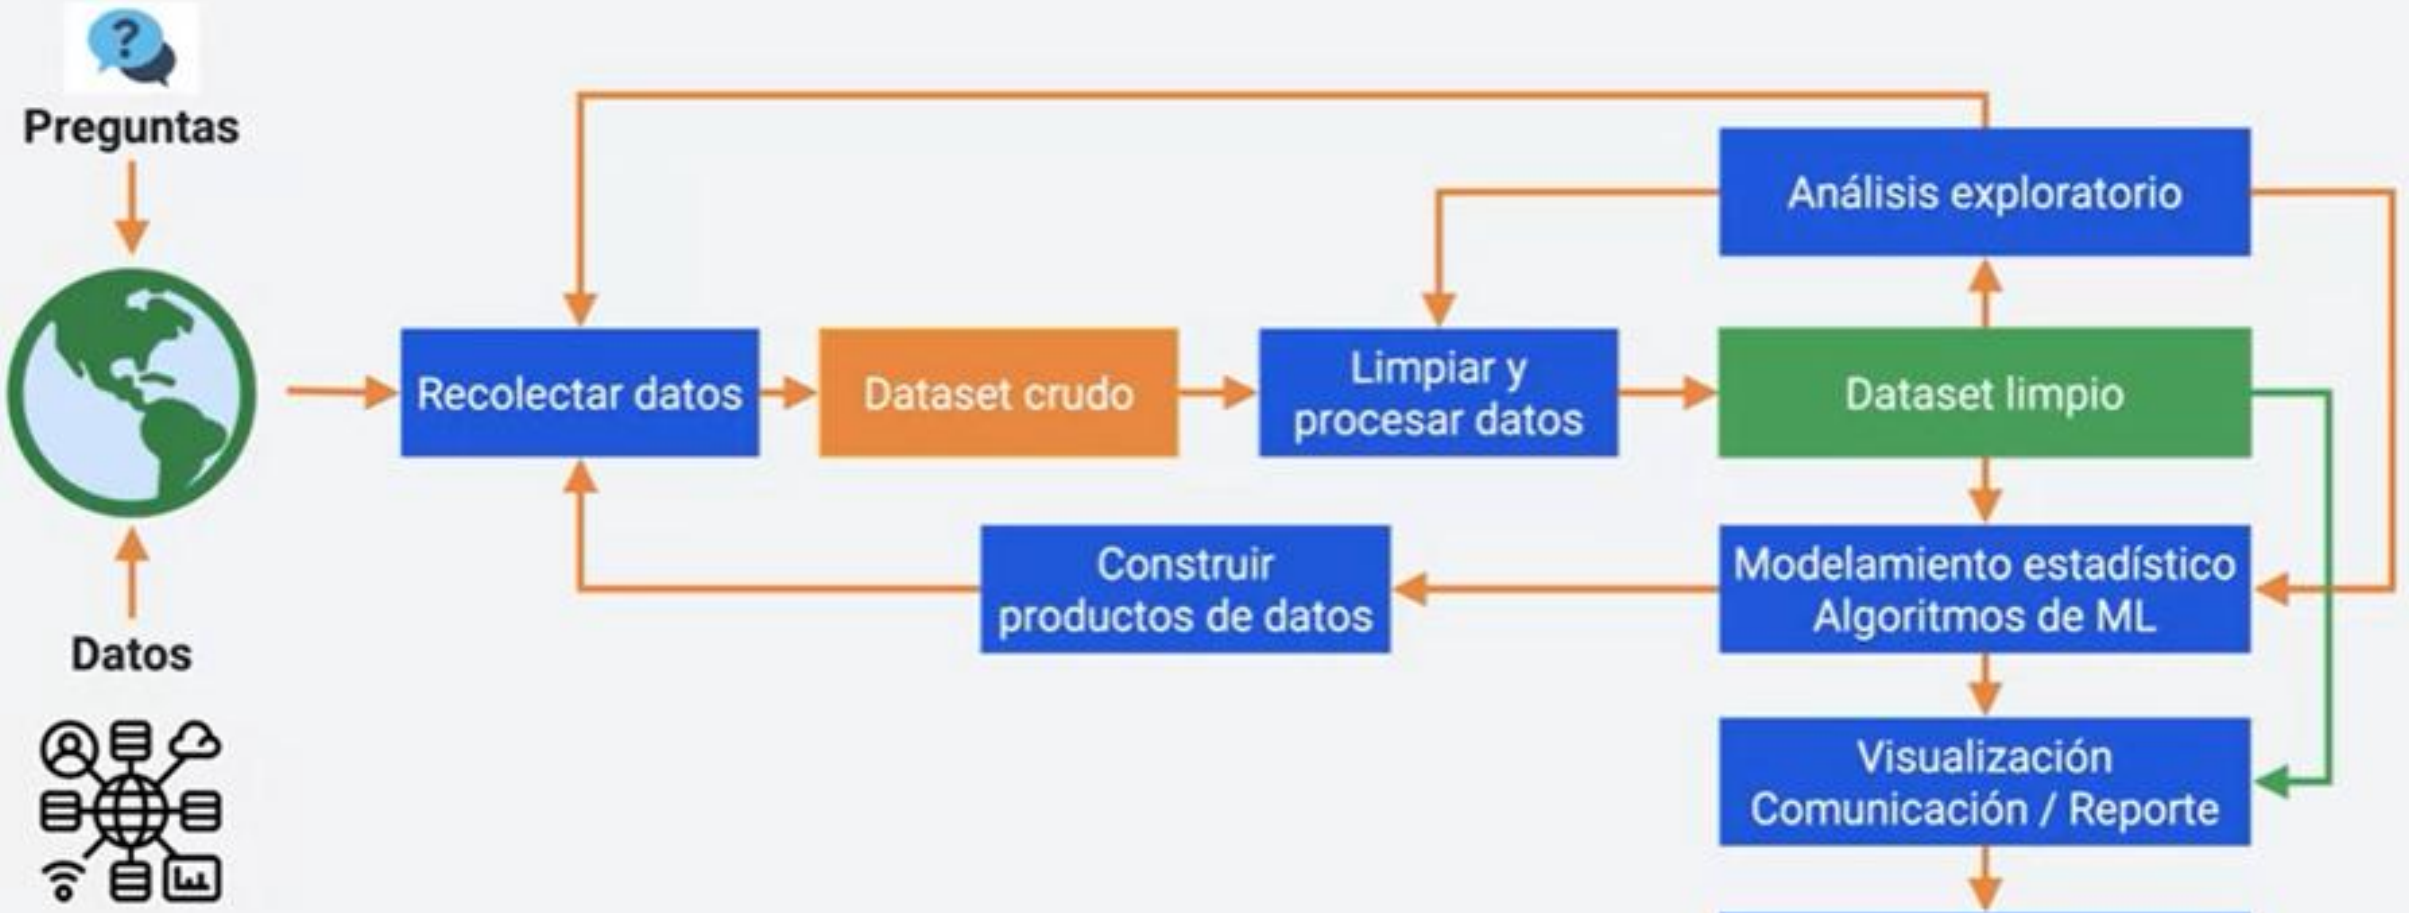
CRISP-DM

Cross-Industry Standard Process for Data Mining, es un método probado para orientar proyectos analíticos.

Como metodología, incluye descripciones de las fases normales de un proyecto, las tareas necesarias en cada fase y una explicación de las relaciones entre las tareas.



PROCESO ANALÍTICO



Fuente: Adaptado de O'Neil, Cathy,Schutt, Rachel. "Doing Data Science", O'Reilly Media.

TAREA

- Crear usuario en Github.
- **Opcional:** seguir todos los pasos de la Guía práctica: Uso de Python, VS Code y Git en computador personal

